



**Universidade de  
Aveiro**

Departamento de Física

**2021**

**RÚBEN BAEZA  
DA SILVA**

**DETEÇÃO AUTOMÁTICA DE FIBRILAÇÃO  
VENTRICULAR ATRAVÉS DO  
ELETROCARDIOGRAMA**

**o júri**

presidente

**Luiz Pereira**

Professora Auxiliar da Universidade de Aveiro

vogais

**Carlos Bastos**

Professor Auxiliar da Universidade de Aveiro (Arguente)

**Doutora Susana Brás**

Investigadora doutorada no IEETA/DETI na universidade de Aveiro

## **Agradecimentos**

Os meus agradecimentos são dirigidos a todos aqueles que possibilitaram a realização deste projeto englobando todos os professores, colegas e familiares que me acompanharam e me ajudaram neste percurso académico. Agradeço de uma forma especial à Professora Susana Brás pela constante ajuda e disponibilidade que presenteou no desenvolvimento deste trabalho. Saliento a ajuda incondicional e acompanhamento constante prestado ao longo deste estudo que, através de críticas construtivas, me permitiu evoluir e aprender bastante nesta área. Tudo isto proporcionado com simpatia e de forma interessada o que tornou este trabalho muito mais fácil.

**palavras-chave**

Fibrilação ventricular, ECG, sensibilidade

**Resumo**

Em Portugal, cerca de um terço das mortalidades anuais são derivadas de doenças cardiovasculares pelo que surge particular preocupação neste tema. Com isto, este trabalho baseia-se na construção de um algoritmo, capaz de detetar fibrilação ventricular explorando características do ECG. De modo a atingir este objetivo o sinal foi sujeito a um pré-processamento e análise de 5 métricas descritas na literatura existente. A análise destas métricas de forma independente permitiu avaliar a sua descrição da patologia. Contudo uma análise multivariável permitirá potenciar o poder discriminatório destas métricas. Numa segunda abordagem foi implementado um algoritmo de unsupervised learning, que permitiu verificar de que forma as métricas se agrupavam permitindo uma discriminação da patologia. Esta análise teve como principal utilidade o estudo da influência das métricas na performance global do modelo. Como o objetivo final deste trabalho é a identificação automática de eventos de fibrilação ventricular, foi implementado também um algoritmo de supervised learning, onde (e tendo em atenção as métricas previamente encontradas como discriminatórias da condição) se obtiveram resultados de  $(92 \pm 0.11)\%$  e  $(87 \pm 0.10)\%$  para a sensibilidade e especificidade, respetivamente. Os resultados obtidos mostraram-se em linha com os reportados na literatura.

**keywords**

Ventricular fibrillation ,ECG, sensibility

**abstract**

In Portugal, about a third of mortalities annually are due to cardiovascular diseases, which is why there is a particular concern about this issue. Thus, this work is based on the construction of an algorithm capable of detecting ventricular fibrillation exploring the characteristics of the ECG. To achieve this goal, the signal was pre-processed and 5 metrics were extracted according to the existing literature. Reviewing these metrics independently allows the description of the pathology. However, multivariate analysis will enhance the discriminatory power of these metrics. In a second approach, an unsupervised learning algorithm was implemented, to verify if the data was grouped, allowing discrimination of the pathology. This analysis was mainly used to study the influence of metrics on the overall performance of the model. As the final objective of this work is the automatic identification of ventricular fibrillation events, a supervised learning algorithm was also implemented, where (and taking into account the metrics previously found as discriminatory of the condition) results of  $(92 \pm 0.11)\%$  and  $(87 \pm 0.10)\%$  were obtained for sensibility and specificity , respectively. The achieved results were in line with those reported in the literature.

## Índice

1	Introdução.....	1
1.1	Eletrocardiograma (ECG).....	1
1.2	Fibrilação ventricular.....	2
1.3	Algumas técnicas e algoritmos para detecção de Fibrilação ventricular.....	3
1.3.1	Spectral (SPEC) .....	3
1.3.2	Algoritmo TCSC.....	4
1.3.3	Método automático para discriminação de arritmias .....	5
2	Algoritmo proposto.....	7
2.1	Pré-Processamento do sinal.....	7
2.1.1	Interferência da rede elétrica.....	8
2.1.2	Correção da linha de base .....	10
2.2	Extração de métricas.....	11
2.2.1	Frequência Fundamental .....	13
2.2.2	Frequência Média.....	14
2.2.3	Potência.....	14
2.2.4	N(%)- Percentagem de amostras que ultrapassam um valor V0 .....	15
2.2.5	F1 ratio .....	17
2.3	Escolha da janela adequada para cálculo das métricas .....	19
2.4	Classificação .....	24
2.4.1	Unsupervised Learning.....	24
2.4.2	Supervised Learning .....	26
3	Resultados e discussão.....	27
3.1	Unsupervised Learning.....	27
3.2	Supervised Learning .....	28
4	Conclusão .....	29
5	Bibliografia .....	30

## **1 Introdução**

Segundo o SNS [1] as doenças cardíacas continuam a ser a principal causa de morte em Portugal sendo responsáveis por mais de 35 mil mortes anuais no nosso território. Estes números refletem cerca de um terço do total das mortalidades anuais nacionais pelo que insurgem numa preocupação extrema neste tema. Especialistas e peritos nesta área afirmam que cerca de 50% destas fatalidades podem ser evitadas com uma alimentação adequada. Além disso, todos nós sabemos que a prática de exercício físico, o controlo do peso, da pressão arterial, diabetes ou colesterol são fatores que ajudam na prevenção de doenças cardiovasculares[2].

Ainda assim a inevitabilidade da ocorrência destes problemas cardíacos obriga a sociedade a tentar encontrar novas soluções para evitar mais casos fatais.

De uma forma geral, toda atividade do coração é derivada de uma condução elétrica intrínseca que comanda o ritmo de contração e dilatação do músculo cardíaco. No entanto, devido a vários fatores este pode sofrer alterações dando origem a arritmias cardíacas.

Neste projeto iremos incidir numa destas arritmias cardíacas denominada fibrilação ventricular.

A fibrilação ventricular é uma condição de emergência onde a frequência cardíaca é descontrolada e extremamente elevada. Na sua grande maioria surge em pacientes com doença cardiovascular prévia como insuficiência cardíaca ou enfarte agudo do miocárdio[3]]. Esta condição acontece prevalentemente fora dos hospitais pelo que é recorrente a ausência de auxílio e consequente morte súbita. Com isto, surge a necessidade de detetar a ocorrência deste tipo de arritmia de modo a ser implementada em um dispositivo médico que possa salvar a vida do paciente.

Com este propósito, temos como objetivo encontrar, estudar e avaliar diferentes características do Eletrocardiograma (ECG) que permitam discriminar a existência de fibrilação ventricular numa porção do ECG.

Neste capítulo iremos introduzir conceitos básicos da génese e interpretação do ECG bem como a sua relevância no diagnóstico e deteção de alterações cardíacas. Além disso a análise será focada na fibrilação ventricular.

### **1.1 Eletrocardiograma (ECG)**

O coração é um dos órgãos primordiais para o ser humano sendo responsável pela circulação de sangue para todas as zonas do corpo. Por sua vez o sangue distribui oxigénio e nutrientes garantindo a sobrevivência das células de todo o nosso organismo. Basicamente existem dois tipos de circulação sanguínea: a circulação pulmonar (pequena circulação) e a circulação sistémica. Na circulação pulmonar o sangue é bombeado do ventrículo direito para os pulmões onde vai ser oxigenado e volta ao coração pela aurícula esquerda. Por outro lado, na circulação sistémica irá ocorrer contração do ventrículo esquerdo que irá bombear o sangue oxigenado para todo o corpo regressando ao coração pela aurícula direita. Toda esta circulação do sangue é regulada através de uma atividade elétrica que comanda os processos de contração e dilatação das aurículas e dos ventrículos.

A atividade elétrica do coração consiste na transmissão dos potenciais de ação através do músculo cardíaco (miocárdio) numa circulação específica. Esta transmissão do impulso elétrico é conseguida através da despolarização de tecidos excitáveis eletricamente que por sua vez irão proporcionar a contração física de células cardíacas [4] Desta forma é possível regular a sístole e diástole cardíaca. A colocação de elétrodos à superfície do nosso corpo irá possibilitar

a medição de pequenas variações do potencial de ação do ritmo cardíaco. O eletrocardiograma (ECG) é, portanto, o registo da soma de todos os potenciais de ação do músculo cardíaco ocorridos num intervalo de tempo [4]. O ECG apresenta uma periodicidade observável pela




Figura 1-Representação das ondas constituintes do ECG. Retirada de [4]

figura 1. A onda P representa a despolarização das aurículas que promove a contração das aurículas que envia o sangue para os ventrículos. Esta despolarização é desencadeada pelo nodo sinoatrial(SA) que inicia todo o círculo cardíaco. De seguida o impulso elétrico passa para o nodo sinoventricular e ocorre o complexo QRS que é composto pelas ondas: Q, R e S e refletindo a despolarização dos ventrículos e consequente contração ventricular. Por fim encontramos a onda T que indica a repolarização dos ventrículos originando o relaxamento ventricular. Além disso, o ECG pode ser dividido em intervalos para facilitar o seu estudo. Assim, define-se primeiro o intervalo PR [4] onde a aurícula contrai e começa a relaxar, com uma duração de aproximadamente 0.16 s. Seguidamente identifica-se

o intervalo QT que se inicia na onda Q e termina na onda T com uma duração de aproximadamente 0.36 s. É de salientar que estes valores podem ser diferentes para cada pessoa, sendo influenciado por muito fatores como a idade, peso ou estado emocional do indivíduo.

Além disso é bastante relevante referir para o nosso projeto que todo o ciclo cardíaco é originado por células específicas denominadas *pacemakers* que geram os impulsos elétricos. Estas células localizam-se no nodo SA, no entanto, por vezes a geração do batimento cardíaco não se realiza neste local, gerando-se um foco ectópico. Esta ocorrência pode originar problemas graves como exemplificaremos já a seguir.

## 1.2 Fibrilação ventricular

Quando o sistema de condução elétrico do coração é afetado podem-se originar arritmias cardíacas. As arritmias cardíacas são batimentos cardíacos anormais [3] que comprometem a periodicidade do ECG. No entanto existem diversos tipos de arritmias cardíacas e podem dividir-se de acordo com as zonas originárias dessa anomalia cardíaca [5]. Destaca-se neste caso as arritmias ventriculares, sendo que nestes casos os *pacemakers* se podem encontrar na rede de Purkinje ou no próprio miocárdio ventricular. Como o impulso elétrico não se propaga no seu caminho normal e gera-se nos ventrículos então, nas arritmias ventriculares, o complexo QRS é largo e assume uma forma diferente do habitual. Na maioria das vezes estes impulsos elétricos originam contrações prematuras ventriculares (PVC). Quando se gera 3 ou mais PVC's é considerada a ocorrência de taquicardia ventricular que assenta numa frequência cardíaca acima de 110 BPM. Se a taquicardia é mantida pode-se originar fibrilação ventricular.

A fibrilação ventricular ocorre quando vários *pacemakers* ectópicos no miocárdio ventricular geram várias contrações simultâneas do músculo cardíaco refletindo-se no ECG pela




Figura 2-Fibrilação ventricular. Retirada de [4]

ausência de um ritmo cardíaco periódico. Aliás não é perceptível no ECG qualquer onda característica e o sinal obtido parece completamente irregular, como é observável na figura 2. Esta condição leva à morte do



indivíduo em poucos minutos caso não se aplique qualquer desfibrilador cardíaco.

### 1.3 Algumas técnicas e algoritmos para detecção de Fibrilação ventricular

Nesta seção iremos abordar alguns algoritmos e técnicas utilizadas para detecção de fibrilação ventricular (VF) entre os quais alguns em que nos baseamos para desenvolver este projeto.

#### 1.3.1 Spectral (SPEC)

O primeiro algoritmo apresentado é um dos mais utilizados para detecção de arritmias ventriculares. Este algoritmo (*SPEC*)[6] analisa o sinal no domínio das frequências pelo que faz uso da transformada de Fourier (*FFT*) do ECG. Análises elaboradas neste domínio concluíram que o ECG com ritmo sinusal varia numa frequência de harmónicos de, aproximadamente, 25Hz enquanto durante a VF o ECG concentra-se numa banda de frequências entre 3-10 Hz[7]. Com maior detalhe podemos caracterizar o espectro do ECG nos dois diferentes episódios segundo o artigo[6]: na VF as frequências apresentam-se concentradas e a rondar, em forma de pequenos picos mais ou menos organizados, a frequência fundamental representada pelo pico maior. Por outro lado no ritmo sinusal (SR) apresentam-se picos com amplitudes variadas até ao vigésimo harmónico. Na figura 3 podemos visualizar as constatações anteriormente referidas.




Figura 3-Módulo da transformada de Fourier para o paciente 1 para as duas condições com valores normalizados em relação ao máximo.

Como em todos os casos o ECG é pré-processado de forma a retirar o ruído do sinal e depois, neste algoritmo, cada segmento do ECG é multiplicado por uma janela de *Hamming*. De seguida é feito o seu *FFT* e a amplitude é calculada através do módulo da *FFT*. Como foi abordado previamente a parte do espectro que nos interessa e que contém maior informação é aquela representada pelos primeiros 20 harmónicos da frequência de referência ( $\Omega$ ). A frequência de referência ( $\Omega$ ) pode ser a frequência fundamental (aquela que tem maior amplitude) que está num intervalo de 0.5-9 Hz. Todas as frequências que não chegam a 5% desta, são eliminadas bem como as de 0-0.5 Hz. Seguidamente são calculadas 4 métricas. A primeira métrica é denominada como o primeiro momento espectral normalizado ( $M$ ) que é dada pela seguinte fórmula:

$$M = \frac{1}{\Omega} \frac{\sum_{j=1}^{jmax} a_j w_j}{\sum_{j=1}^{jmax} a_j} \quad (1)$$

Onde  $w_j$  é a  $j$ -ésima frequência do *FFT* entre 0 Hz e os 20 primeiros harmônicos ( $20\Omega$ ), exceto quando  $20\Omega$  ultrapassa 100 Hz, sendo nesse caso entre 0 e 100 Hz. Este critério mantém-se para as seguintes métricas. O parâmetro  $a_j$  é a amplitude da frequência  $j$  correspondente. Valores próximos de 1 para  $M$  indica uma elevada concentração do espectro em torno da frequência  $\Omega$  o que poderá indicar a presença de VF.

Depois são calculadas A1, A2 e A3. A métrica A1 é a soma das amplitudes entre 0.5 Hz e  $\Omega/2$ , dividido pela soma das amplitudes entre 0.5 Hz e  $20\Omega$ . A2 é a soma das amplitudes entre  $0.7\Omega$  e  $1.4\Omega$  dividido pela soma das amplitudes entre 0.5 Hz e  $20\Omega$ . A3 é a soma das amplitudes em bandas de 0.6 Hz a entre o segundo até o oitavo harmônico ( $2\Omega - 8\Omega$ ), dividido pela soma das amplitudes entre 0.5 Hz e  $20\Omega$ .

Depois de uma análise destas métricas segundo o artigo [6], se  $A1 < 0.19$ ,  $M < 1.55$ ,  $A2 > 0.45$  e  $A3 < 0.09$  então deteta-se fibrilação ventricular.

Apresenta-se na tabela 1 os resultados obtidos segundo o artigo [7] para este algoritmo quando se utiliza a base de dados online CU que é aquela que iremos usar.

	Especificidade(%)	Sensibilidade(%)
<b>SPEC</b>	37.18	98.82

Tabela 1-Resultados do algoritmo SPEC quando se utiliza a base de dados Cu, segundo, [7]

### 1.3.2 Algoritmo TCSC

Ao contrário do *SPEC* este algoritmo foca-se na análise do sinal no domínio temporal para extrair características relevantes do ECG que permitem a deteção da VF. Este algoritmo baseia-se no número de amostras que passam um certo limite  $V0$  [8], pré-definido como 0.2 depois de testes empíricos. Assim, primeiramente é analisado e investigado cada segmento de 3s do ECG. Cada segmento é pré-processado e multiplicado por uma janela definida como  $W(t)$ :

$$W(t) = \begin{cases} 0.5(1 - \cos(4\pi t)), & 0 \leq t \leq \frac{1}{4} \\ 1, & \frac{1}{4} \leq t \leq Ls - \frac{1}{4} \\ 0.5(1 - \cos(4\pi t)), & Ls - \frac{1}{4} \leq t \leq Ls \end{cases}, \text{ sendo } Ls \text{ o segmento de 3s.}$$

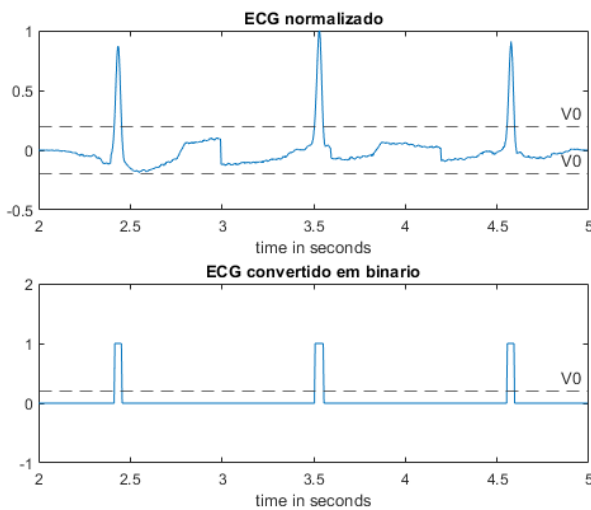


Figura 4-Conversão de um segmento ECG normalizado de ritmo sinusal em binário após passagem pelo limite  $V0$  para o paciente 1 (cu01)

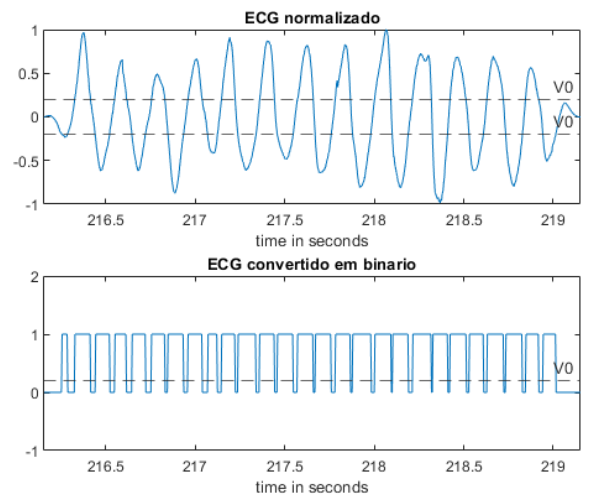


Figura 5- Conversão de um segmento ECG normalizado com Fibrilação Ventricular em binário após passagem pelo limite  $V0$  para o paciente 1 (cu01)

De seguida cada segmento de 3 s multiplicado por  $w(t)$  é normalizado de modo a estar contido entre 0 e 1. O próximo passo é converter esta janela de ECG num sinal binário, como apresentado nas figuras 4 e 5. Deste modo, se uma determinada amostra do ECG ultrapassa  $V_0$  ou  $-V_0$ , essa amostra é contabilizada como 1, caso contrário é-lhe atribuído o valor de 0. De seguida obtém-se a percentagem de amostras que ultrapassaram esse limite ( $N\%$ ), dividindo o número de 1's pelo número total de amostras em percentagem. Finalmente é calculado a métrica  $Na$ , obtida através da média de  $N\%$  valores num intervalo de tempo maior que 3-s.

No final, a fibrilação ventricular é detetada caso  $Na > Nd$ , sendo  $Nd$  um limite crítico ajustado para obter melhor especificidade. Após diversos testes, segundo o artigo [8], o valor adequado para  $Nd$  era de 48. Assim, para a base de dados CU que é a nossa escolhida nesse projeto como iremos abordar no próximo capítulo, obteve-se os seguintes resultados apresentados na tabela 2.

	Especificidade(%)	Sensibilidade(%)
TCSC	79.74	88.14

Tabela 2-Resultados do algoritmo TCSC quando se utiliza a base de dados Cu, segundo, [6]

### 1.3.3 Método automático para discriminação de arritmias

O algoritmo aqui apresentado é retirado do artigo [9] que visa a deteção automática de várias anomalias cardíacas que se rege a partir de um conjunto de regras de decisão. A primeira regra de decisão é a diferenciação entre “VF” ou “não VF” e é este propósito que serve o pretendido para este projeto. Assim apenas iremos descrever o algoritmo utilizado para a deteção de fibrilação ventricular.

Este método extrai seis métricas distintas em que quatro delas são obtidas através de dois gráficos bastante peculiares elaborados através do ECG e são estas que vamos focar para este projeto.

Na primeira etapa desenvolve-se um primeiro gráfico em que a sua abcissa(x) são as amostras do ECG analisado ( $s_1, s_2, s_3, \dots, s_i$ ) e as ordenadas(y) são as mesmas amostras adiantadas de uma amostra ( $s_2, s_3, s_4, \dots, s_{i+1}$ ). A elaboração do segundo gráfico é bastante semelhante ao primeiro, no entanto, para este último colocámos um adiantamento de 5 amostras nas ordenadas ( $s_{i+5}$ ) comparativamente às abcissas. Segue-se na figura 6 um exemplo demonstrativo.

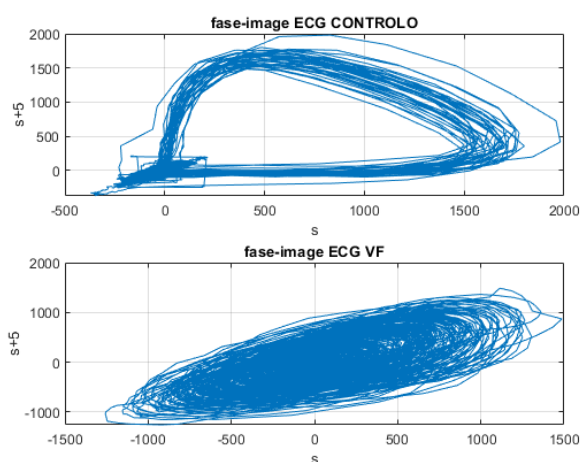


Figura 6- Gráficos do ECG do paciente 1 com as ordenadas adiantadas de 5 amostras relativamente às abcissas.




Figura 7-Gráfico convertido em binário para o ECG do paciente 1 com as ordenadas adiantadas de 5 amostras relativamente às abcissas

Ao desenvolver estes gráficos verificou-se segundo o artigo [9] que para segmentos de ECG com ritmo sinusal estes mostram linhas distintas e mais organizadas. No entanto, os gráficos para ECG's com VF apresentam linhas mal definidas e muito mais desorganizadas e irregulares especialmente para o gráfico com um adiantamento de cinco amostras.

De modo a estudar melhor estes gráficos e a extrair as métricas, estes gráficos são convertidos em imagens binárias que consistem em pixéis de 1s (pixéis brancos) e 0s (pixels pretos). Na figura 7 apresenta-se uma ilustração desta conversão.

No gráfico elaborado para o ECG com VF verificamos que as linhas são aleatoriamente distribuídas ao longo de todo o gráfico, logo sendo os pixéis pretos as linhas podemos inferir que existirá maior quantidade de pixéis pretos nas zonas com VF. Assim, nesta fase, este método baseia-se na extração de 4 métricas analisando estes gráficos binários. Primeiramente extrai-se a métrica *F1* que se baseia na fração entre o número de pixéis pretos sobre o número total de pixéis da imagem(*r*). Seguidamente para o cálculo de *F1* é efetuada a subtração entre esta fração(*r2*) do gráfico 2 (gráfico com 5 amostras adiantadas) e a fração do gráfico 1(*r1*). Espera-se que *F1* seja maior para VF. De seguida calcula-se *F2* que representa o número de linhas na imagem binária que estão inclinadas de 45°. Da mesma forma pela visualização dos gráficos é espetável que esta métrica seja maior para VF. O cálculo de *F3* é bastante semelhante que *F2* já que *F3* contabiliza o número de pixéis que ocupam as linhas inclinadas de 45°. Por fim, a última característica *F4* é extraída através de um processo bastante complicado que inclui um processamento de imagem e abrange todas as outras três métricas. Basicamente *F4* foca-se num processo de realçar as diferenças e de cálculo da área preta do gráfico. Como existe maior número de pixéis pretos no gráfico de um ECG com VF, logo é possível antecipar um maior valor de *F4* para VF.

De seguida neste algoritmo são extraídas mais duas métricas que já não se baseiam na avaliação destes gráficos de imagem que são de certa forma peculiares. A quinta característica, *F5* é adquirida através da análise do segmento de ECG no domínio da frequência tal como o algoritmo anteriormente abordado *SPEC*. Mais precisamente é utilizado um espectro de potência em que todas as amplitudes estão normalizadas em relação à amplitude máxima. A característica extraída (*F5*) é amplitude espectral média em toda a região. Espera-se que para segmentos com VF esta característica seja mais baixa como é possível observar pela figura 3 construída no método de *SPEC*.

Por último a sexta métrica *F6* é conseguida através da entropia *Shannon* do sinal (*SE*) calculada através da expressão:

$$H(S) = - \sum_i^n p_i \log 2 p_i \quad (2)$$

Espera-se que *SE* seja maior para zonas de fibrilação.

Por fim, são utilizados dois classificadores distintos, uma árvore de decisão binária (BDT) e um vetor de suporte de máquina (SVM).

Classificador	Especificidade(%)	Sensibilidade(%)
BDT	94.2	94.5
SVM	91.6	89.3

Tabela 3- Resultados do algoritmo TCSC quando se utiliza a base de dados Cu

## 2 Algoritmo proposto

Este projeto tem como objetivo apresentar um novo algoritmo para detecção de fibrilação ventricular. Ainda assim, o foco e objetivo deste projeto não se limita somente a obter bons resultados de classificação e detecção da doença, mas principalmente à exploração e avaliação da combinação de diferentes métricas do ECG e a sua discriminação da condição patológica.

Antes de mais procedeu-se à escolha da base de dados na qual todo o projeto irá ser desenvolvido. A escolha recaiu na CU *Ventricular Tachyarrhythmia Database* [10] disponível no website *Physionet*[11]. Esta base de dados inclui 35 ECG's de pacientes que experienciaram períodos de taquicardia ventricular e fibrilação ventricular. O ECG de cada indivíduo foi adquirido com uma frequência de amostragem de 250 Hz durante cerca de 8.5 minutos correspondente a 127 mil e 232 amostras. Além disso, cada sinal foi já sujeito a um filtro passa-baixo de segunda ordem com uma frequência de corte de 70 Hz. O facto de esta base de dados ter uma quantidade significativa de participantes e dispor de uma frequência de amostragem suficientemente alta levou à seleção da mesma para a elaboração deste projeto.

Uma observação bastante importante é o facto de cada sujeito apresentar anotações efetuadas por especialistas na área durante os 8.5 minutos do seu ECG que indicam o estado do eletrocardiograma, incluindo os momentos onde ocorreram episódios de fibrilação ventricular.

No entanto é relevante referir que se efetuou uma seleção dos sinais que foram utilizados neste trabalho de modo a obter-se um balanceamento adequado entre a quantidade de participantes e o número de amostras que apresentam a patologia. Este passo realizou-se já que o número de participantes é muito importante em termos estatísticos e na fiabilidade dos nossos resultados finais bem como é relevante que não se perca demasiada informação do ECG.

Assim da base de dados original escolhemos 25 sujeitos em que cada um deles dispõe de pelo menos 10 mil amostras (40s) para cada episódio de fibrilação e sem fibrilação (grupo controlo). Esta estratégia adotada permite que tenhamos um número considerável de participantes e ao mesmo tempo sem perda de demasiada informação do sinal de ECG.

Deste modo neste capítulo abordaremos o modo como todo o algoritmo foi elaborado compreendendo no seu processo: a filtragem do sinal, a respetiva seleção e extração de métricas, a escolha de janelas temporais para cálculo das métricas, a avaliação das mesmas e ainda a metodologia para a classificação. A figura 8 representa esquematicamente as diferentes fases do algoritmo definido.



Figura 4-Esquema representativo do algoritmo elaborado

### 2.1 Pré-Processamento do sinal

O eletrocardiograma (ECG) reflete a atividade elétrica do coração e é crucial no diagnóstico e detecção de patologias cardíacas. Estas doenças podem ser reconhecidas principalmente pela extração de métricas que poderão traduzir ou indicar a presença de determinada anomalia.

No entanto, para uma correta análise do ECG é necessário efetuar um pré-processamento do mesmo antes de partir para um estudo mais aprofundado.

O pré processamento consiste na atenuação de toda a informação irrelevante do sinal que contamina e impede uma precisa avaliação do mesmo. Esta informação irrelevante é comumente apelidada como ruído.

### 2.1.1 Interferência da rede elétrica

O ECG de um certo indivíduo é obtido através da colocação de elétrodos em zonas específicas do corpo humano. Estes elétrodos detetam o fluxo iónico [5] dentro do corpo pela medição da diferença de potencial entre eles pelo que a direção e correta colocação dos mesmos é fundamental para uma boa visualização e aquisição do ECG. Na maioria das vezes nestes tipos de instrumentação um elétrodo é tido como referência (terra) e é conectado a um amplificador que por sua vez irá amplificar então o sinal em modo comum que corresponde à interferência da rede elétrica. Esta interferência é aquela que pretendemos remover e possui uma frequência fundamental de cerca de 50/60 Hz.

Com este propósito é necessário construir um filtro que permita remover estes harmónicos e artefactos de 60Hz.

A principal funcionalidade de um filtro é ter a capacidade de, quando aplicado a um determinado sinal, conseguir fazer modificações vantajosas no domínio das frequências a esse sinal. Há vários tipos de filtros que alteram de diferentes formas a expressão de certas frequências do sinal entre os quais os mais usados: passa-baixo, passa-alto e passa-banda. Um passa-baixo irá deixar “passar” as frequências mais baixas do sinal até uma determinada frequência de corte ( $F_c$ ). O passa-alto como o nome indica elimina as frequências mais baixas do sinal até à  $F_c$  e o passa-banda irá deixar passar apenas um intervalo de frequências.

Todos os filtros existentes podem ser representados pela sua função de transferência ( $H(z)$ ) que é obtida através do quociente entre a sua saída ( $Y(z)$ ) e a sua entrada ( $X(z)$ ) [12], tudo no domínio  $Z$ . Assim a função de transferência de um filtro pode ser representada pela seguinte expressão:

$$H(z) = \frac{b_0 + b_1 z^{-1} + b_2 z^{-2} + \dots + b_M z^{-M}}{1 + a_1 z^{-1} + a_2 z^{-2} + \dots + a_N z^{-N}} \quad (3)$$

, em que  $M$  e  $N$  referem-se à ordem do numerador e denominador, respetivamente. Como  $N$  é na maioria dos casos maior que  $M$ , então  $N$  também será a ordem do filtro. As variáveis  $b_n$  e  $a_n$  são os coeficientes do filtro e é através destes que conseguimos implementar qualquer filtro em diversas plataformas computacionais, no nosso caso o *MATLAB*.

Além disso, é importante referir que os zeros do numerador são caracterizados como zeros do filtro. Por outro lado, os zeros do denominador são designados como polos. Estes dois conceitos são bastante relevantes porque é através de propriedades destes que vamos poder desenhar um filtro adequado ao pretendido. Os zeros e polos podem assumir na maioria das vezes números complexos com o seu respetivo módulo e fase [12] e podem ser descritos através da fórmula de Euler:  $r_i e^{j\theta_i}$ , sendo  $r_i$  o módulo do número complexo e  $\theta_i$  a sua fase.

Uma propriedade primordial dos zeros e dos polos que se utilizou na construção do nosso filtro é o facto de estes terem um poder enorme na escolha das frequências que pretendemos modelar o ganho do sinal. Através de vários estudos provou-se que a fase dos zeros em rad/amostra corresponde à frequência que o filtro rejeita e onde o ganho é menor [12]. Pelo contrário a fase dos polos definem as frequências com o ganho maior. Assim, como pretendemos retirar a interferência da rede elétrica que possui uma frequência de 60 Hz basta definir a fase em frequência angular normalizada (rad/amostra) do zero que corresponde à frequência de 60 Hz. O cálculo feito [13] corresponde para a conversão em frequência angular normalizada foi:  $(60/F_s)2\pi$  já que  $w=2\pi f$ . A divisão da frequência de amostragem é devido à digitalização do sinal.

A partir do *MATLAB* definimos os zeros como número complexo na fórmula de Euler onde colocamos a respetiva fase anteriormente calculada e um módulo de 1. É de notar que o

módulo do zero não afeta muito a resposta do filtro. A implementação de filtros no *MATLAB* é efetuado através da função *filter* ou *filtfilt* onde temos como parâmetro de entrada o sinal que pretende-se filtrar e os coeficientes do numerador e denominador da função de transferência do filtro. Quanto ao denominador nós definimos previamente os seus zeros pelo que podemos escrever a sua expressão polinomial. No *MATLAB* existe a função *poly* que devolve os coeficientes da expressão polinomial quando fornecemos os seus zeros como parâmetros de entrada. Com isto conseguimos elaborar o nosso filtro e segue-se nas figuras abaixo a respetiva resposta em frequência:

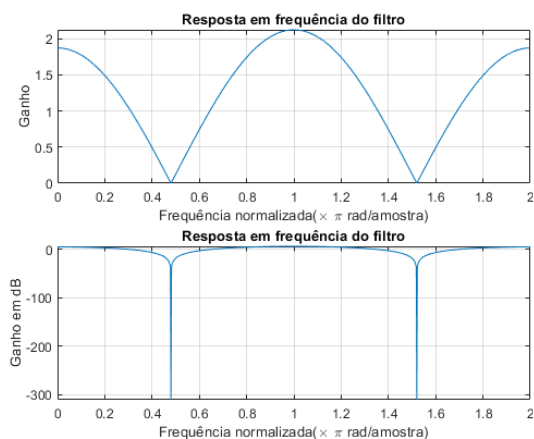


Figura 5-Resposta em frequência do filtro contruído




Figura 6-Mapa de polos e zeros para o filtro elaborado

Como podemos confirmar pela figura 9 o ganho do filtro é mínimo para a frequência normalizada de  $0.48\pi$  que corresponde a 60 Hz na frequência física. Com isto, elaboramos com sucesso o nosso filtro.

Concluída a construção do filtro, aplicamos então este aos nossos ECG's da base de dados selecionadas. Segue-se na figura 11 um caso exemplificativo do ECG do paciente 1 (cu01) antes e depois da aplicação do filtro.

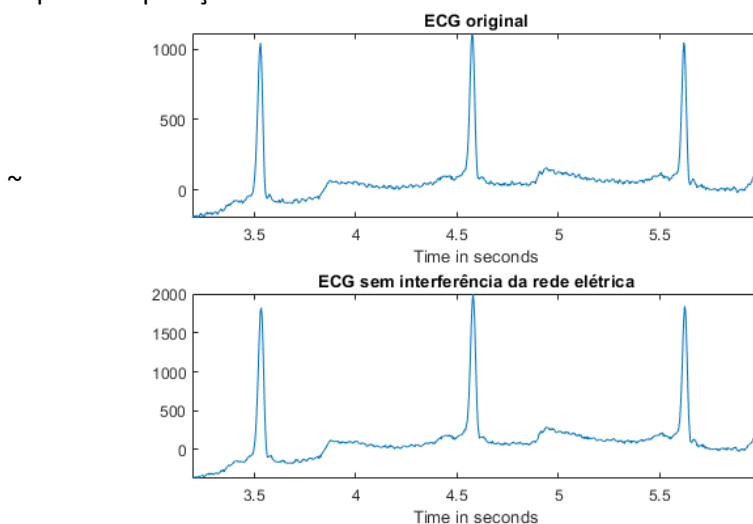


Figura 7-Aplicação do filtro para remoção da rede elétrica

Apesar de a diferença não ser tão evidente podemos observar uma diminuição das pequenas oscilações no gráfico inferior comparativamente com o superior em que o sinal não está filtrado.


### 2.1.2 Correção da linha de base

Muitas vezes o ECG original apresenta oscilações de muito baixa frequência na sua linha de base. Isto pode ser causado pela respiração ou movimento do paciente no momento em que os dados foram adquiridos. Estes movimentos oscilatórios apresentam frequências a rondar os 0.15 e os 0.3 Hz.

Este ruído deve ser removido antes de se efetuar a análise e extração de informações relevantes ao biosinal. Assim, uma forma de eliminar este ruído é aplicar uma moving average filtering[5].

Primeiramente extraiu-se as amostras referentes aos primeiros 200 ms correspondente ao tempo do intervalo PR do ECG e calcula-se a sua média. Posteriormente efetua-se o mesmo procedimento para as restantes 200 ms de amostras e assim sucessivamente até ao fim do sinal. De seguida esses valores médios obtidos servem de entrada para outro procedimento muito semelhante. Assim, para cada intervalo de amostras representantes de 600 ms é calculada a sua média e deste modo continuamente até ao final do sinal.

Por fim para remover as oscilações da linha de base é preciso subtrair os valores médios calculados ao sinal original. Através da figura 12 representada a seguir é possível verificar a tal correção da linha de base.



*Figura 8-Aplicação do moving average filtering para correção da linha de base no paciente 1 (cu01)*

Como conseguimos observar pela figura 12, é bastante clarividente que a aplicação deste tipo de filtro conseguiu remover com sucesso o movimento harmónico da linha de base. É de notar que existem diferentes maneiras e diversos filtros para corrigir esta linha de base, no entanto este foi elaborado e os resultados foram bastante satisfatórios pelo que não se considerou ser necessário partir para outras abordagens.

Por fim, com a execução deste pré-processamento conseguimos remover todas as fontes de ruído mais evidentes não sendo observável muito ruído passível de ser eliminado sem ser o que foi aqui demonstrado. No entanto, é de salientar que, ainda que tenhamos eliminado a maior parte do ruído dos ECG's, existe sempre porções do sinal que não apresentam informação passível de ser lida ou útil proveniente da má qualidade na aquisição do sinal. Ainda assim, efetuou-se pequenas correções ao sinal já que por vezes ocorria que alguns valores isolados eram de uma ordem de grandeza extremamente superiores aos demais, pelo que, nesses casos, substituíam-se pelo valor máximo do limite pré-definido.



## 2.2 Extração de métricas

O pré-processamento anteriormente explicitado permitiu remover o principal ruído que contamina os biosinais que se pretende estudar. Com esta informação irrelevante eliminada é possível então extrair características do ECG que nos irão possibilitar o reconhecimento e detecção da condição de fibrilação ventricular.

Desta forma, nesta subseção introduziremos e explicaremos com detalhe as características escolhidas e extraídas do nosso sinal de ECG bem como os resultados obtidos para cada uma dessas métricas.

### Introdução à análise no domínio espectral

A grande maioria dos sinais biomédicos exibem ritmos e periodicidades pelo que é muitas vezes relevante a sua análise no domínio da frequência. Esta análise e extração de informação neste novo domínio pode ser de uma ajuda muito preponderante no diagnóstico de doenças.

A nossa base de dados está definida no domínio temporal já que o sinal foi adquirido e registado ao longo do tempo com uma frequência de amostragem de 250 amostras por segundo. No entanto sabemos que é possível converter e analisar o sinal no domínio espectral usando a transformada de Fourier discreta [14]:

$$X(k) = \frac{1}{N} \sum_{n=0}^{N-1} x(n) e^{-j\frac{2\pi}{N}kn} \quad (4)$$

Onde  $X(k)$  representa os  $N$  coeficientes no domínio das frequências e  $2\pi/N$ , a resolução em frequência em radianos/amostra.

Com isto utilizamos a plataforma computacional do *MATLAB* e usufruímos da função *fft* que elabora a transformada de Fourier sobre o sinal discreto inserido. Além disso definimos a resolução em frequência dada pela frequência de amostragem sobre o número total de amostras do sinal. A resolução em frequência estabelece o espaçamento mínimo entre as frequências existentes do sinal discreto em Hz.

Como o nosso objetivo é encontrar parâmetros que permitem distinguir entre fibrilação ventricular e a não existência da mesma o nosso foco foi analisar os dois tipos de sinais. Assim escolheu-se e retirou-se uma porção de 10000 amostras de um episódio onde ocorre a patologia e outra porção com a mesma dimensão onde o ritmo cardíaco se apresenta saudável. Esta extração e avaliação é feita sempre para cada um dos pacientes. Mostra-se a seguir os resultados obtidos para o paciente 1 (cu01):

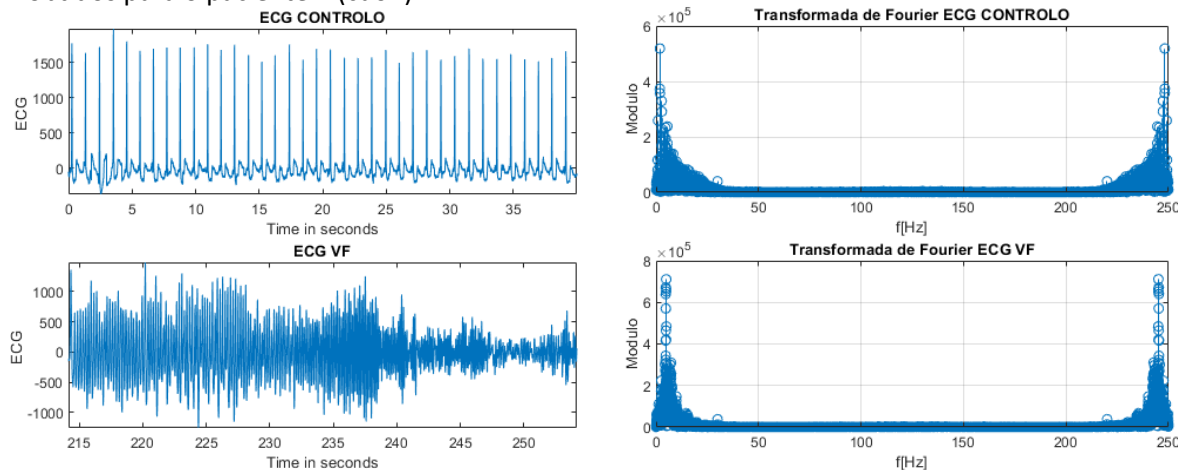


Figura 9-Apresentação dos sinais no domínio temporal no lado esquerdo e no domínio espectral do lado direito para o ECG controlo sem patologia e ECG com patologia. Nota: VF-Fibrilação Ventricular.

Através da análise da figura 13 podemos observar as diferenças nítidas no domínio temporal entre a fibrilação ventricular e um ritmo sinusal. No ritmo sinusal que está identificado como ECG de controlo é visível a periodicidade do ritmo cardíaco bem como todas as suas ondas, picos e segmentos característicos (complexo QRS, picos R, etc). Pelo contrário no ECG com a patologia não é observável nenhum padrão nem nenhuma das características de um ECG comum como os seus segmentos e picos além de que, o ritmo cardíaco parece totalmente descontrolado e sem qualquer periodicidade visível. Ora se isto acontece no domínio temporal, no domínio espectral estas observações não são assim tão evidentes. No entanto, se fizermos uma análise mais precisa e atenta podemos verificar que, no caso deste paciente, no espectro referente à patologia podemos ver que as frequências mais evidenciadas rondam os 5 Hz em contraste com o espectro sem doença onde o espectro se concentra mais no início das frequências, com a mais destacada a de 2 Hz. Uma propriedade bastante importante na análise da FFT é que a transformada de Fourier apresenta simetria ( $X(k)=X(-k)$ ), pelo que só interessa para a análise a primeira metade do gráfico.

No entanto quando tratamos de sinais reais onde às vezes a qualidade dos sinais adquiridos não é a melhor e pode mesmo ter algum ruído, por vezes é melhor utilizar para o estudo do sinal, a densidade espectral de potência.

A análise da densidade espectral de potência (PSD) é um procedimento muito útil e comum em vários sinais biomédicos. Uma maneira de estimar esta medida é calcular o quadrado do valor absoluto da *Fast Fourier Transform* (FFT). Existem várias formas de calcular e obter a PSD e todas elas baseiam-se no periodograma.

O periodograma [12] é calculado a partir da FFT do sinal  $x(n)$  através da seguinte expressão:

$$S(e^{j\Omega}) = \frac{1}{N} |X(e^{j\Omega})|^2, \text{ onde } X(e^{j\Omega}) \text{ é FFT do sinal } x(n) \text{ com } N \text{ amostras.} \quad (5)$$

Os valores do periodograma  $S(e^{j\Omega})$  são então calculados para cada frequência com intervalos entre frequências de  $\Omega = 2\pi/N$ , correspondendo à resolução em frequência do sistema em radianos ou  $res = fa/N$  se pretendemos visualizar em Hz.

No entanto, uma forma de calcular a PSD é através do método *Welch Power Spectral Density*.

A *Welch Power Spectral Density* [12] é calculada através de médias dos periodogramas. Primeiramente o sinal é dividido em  $K$  segmentos com  $M$  amostras. No entanto, na grande maioria das vezes estes segmentos têm uma certa percentagem de sobreposição. De seguida cada segmento é multiplicado por uma janela  $w(n)$  (*Hanning, Hann, Kaiser, Retangular*, etc.). Só depois de serem aplicados estes passos todos a um segmento é que este é sujeito à transformada de Fourier e respetivo cálculo do periodograma.

Finalmente é elaborada a média dos periodogramas sobre o número total de segmentos  $K$ , como sugere a expressão :

$$S_w(e^{j\Omega}) = \frac{1}{K} \sum_{k=1}^K S_{w_k}(e^{j\Omega}) \quad (6)$$

Como mencionado ao longo de toda esta descrição elaboramos e implementados através do *MATLAB* este método de estimação da densidade espectral WELCH. Para isso utilizámos diretamente a função do *MATLAB* *pwelch*, com 50% sobreposição e janela retangular e de modo a obter uma resolução em frequência de 0.5 Hz. É de notar que a função devolve os valores do método Welch ( $S_w$ ) dividido pela  $Fa$  e o domínio de frequências em Hz, e que, portanto, foi elaborado um *plot* de  $10 \times \log_{10}(S_w)$  pelo que os valores da potência serão em Décibéis/Hz.

Com isto, elaborou-se a estimação da densidade potência espectral pelo método de Welch para as mesmas 2 porções de sinais com 10k amostras antes analisados mantendo-se o

objetivo de verificar as diferenças entre o ECG que apresenta fibrilação ventricular daquele sem a anomalia cardíaca. Apresenta-se de seguida os gráficos obtidos:

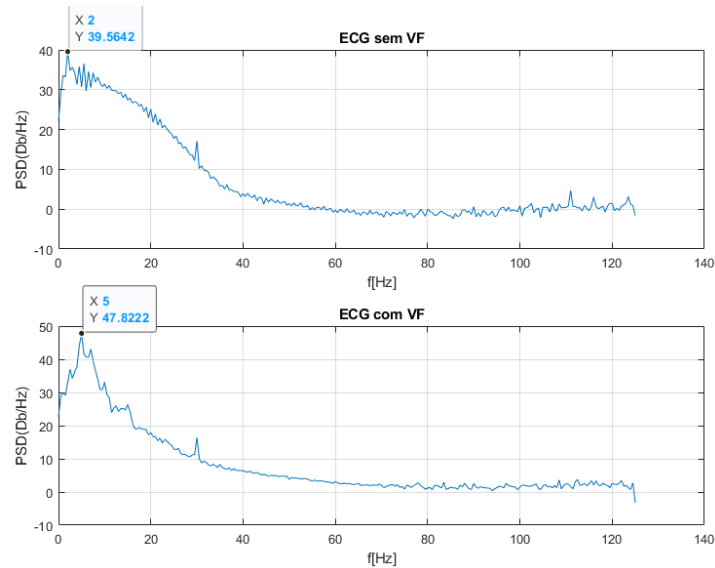


Figura 10-Densidade espectral de potência para o paciente 1 (cu01).Nota: VF-Fibrilação Ventricular

A observação e análise da figura 14 confirma as primeiras impressões relativas ao módulo da transformada de Fourier e que, para este paciente, as frequências predominantes no ECG sem a anomalia são mais baixas do que aquele que apresenta a doença.

No entanto iremos fazer uma análise mais profunda a estas características espectrais dos nossos sinais e consequentemente as nossas três primeiras métricas são adquiridas e calculadas a partir destas avaliações.

### 2.2.1 Frequência Fundamental

A primeira característica que se extraiu no nosso ECG é precisamente a frequência fundamental obtida através da densidade espectral de potência relatada anteriormente. A frequência fundamental é a frequência que é predominante num certo sinal, ou seja, é aquela que é mais forte e que contribui mais para a densidade de potência de entre todos os harmónicos que compõe, no nosso caso o ECG. No gráfico da densidade espectral de potência de um sinal a frequência fundamental é visualizável como o pico mais alto. Com isto, para cada paciente, avaliou-se novamente a parte do ECG que apresentava a patologia e outra parte do biosinal que, pelo contrário, exprimia um ritmo cardíaco sinusal. De salientar que estas duas porções do sinal têm ambas dimensão de 10000 amostras tal como referido no início deste capítulo. Além disso é de notar também que analisaremos todas as métricas sempre para as mesmas porções de ECG de cada paciente.

Procedemos desta maneira para todos os pacientes e encontramos assim as frequências fundamentais para o caso do ECG sofrer de fibrilação ou não. Conseguimos assim, verificar certas diferenças quando avaliámos esta característica do ECG. No entanto apresentaremos os resultados precisos mais à frente neste capítulo já que todo este código foi elaborado em janelas que percorrem este segmento analisado para o resultado ser mais consistente. A explicação e elaboração destas janelas será abordado posteriormente. Segue-se uma figura exemplificativa de como visualizar a frequência fundamental através da densidade espectral de potência como sendo o pico mais alto.




Figura 11-Visualização da frequência fundamental através da densidade espectral de potência para o paciente 1.

### 2.2.2 Frequência Média

A segunda característica que avaliaremos neste projeto é a frequência média do sinal. Ao contrário da frequência fundamental a frequência média não é a frequência mais predominante e evidente do sinal. Todas as frequências existentes no sinal analisado têm contribuições para a densidade de potência do sinal, no entanto umas mais que outras. Ora verificando estas contribuições e através de alguns cálculos podemos encontrar a frequência média do ECG. Como mencionado anteriormente a função *pwelch* que permite a elaboração da densidade espectral de potência vai criar dois vetores  $S_w$  e  $F_w$ . Com isto, como  $S_w$  apresenta as contribuições para cada frequência na densidade de potência[15] podemos normalizar este vetor de forma a que a sua soma seja unitária:

$$\tilde{S}_k = \frac{S_k}{\sum_k S_k}, k=1, 2, \dots, K \quad (7)$$

Com o respetivo vetor normalizado  $S_w$  torna-se fácil calcular a frequência média. Ora basta multiplicar para cada frequência pelo respetivo valor de aporte à densidade de potência e no final somar todos estes valores.

Repetimos todo este processo para todos os pacientes e obviamente, para cada um deles, calculamos a frequência média num segmento de ECG com a respetiva anomalia cardíaca e noutra porção com ritmo sinusal.

Novamente, os resultados serão discutidos em seções posteriores.

### 2.2.3 Potência

A última métrica que extraímos a partir da análise espectral do nosso sinal é a potência. A potência do ECG pode ser calculada mais uma vez a partir da densidade espectral do sinal. Como a densidade espectral revela-nos a potência que cada frequência contribui para o sinal, se somarmos a contribuição de todas as frequências[15] teremos então a potência total do segmento analisado. Assim a potência total não é mais que a área de todo o gráfico da densidade espectral.

Novamente, procedemos de igual maneira para todos os pacientes de modo a verificar as diferenças entre fibrilação ventricular e não fibrilação ventricular.

Segue-se uma ilustração gráfica da potência na figura 16, onde podemos ver a área a que nos estamos a referir.

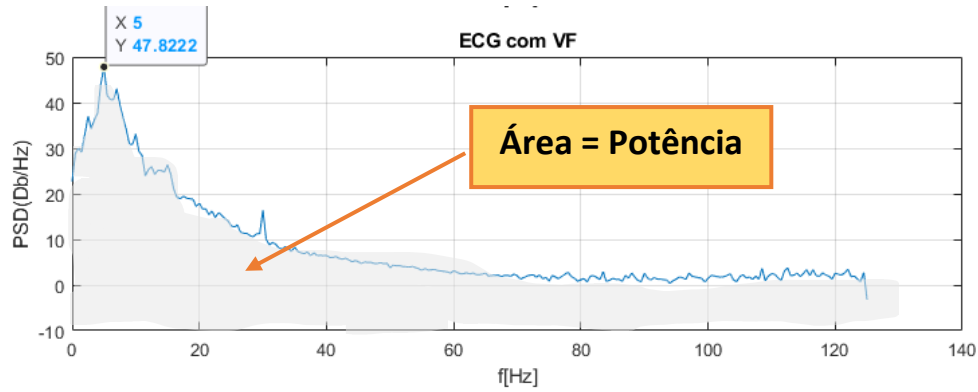


Figura 12-Visualização da potência através da densidade espectral de potência para o paciente 1(cu01)

#### 2.2.4 N(%)- Percentagem de amostras que ultrapassam um valor V0

As duas novas métricas apresentadas são obtidas através de uma análise do ECG no domínio temporal.

No capítulo 1 descrevemos algumas das técnicas existentes para a detecção ventricular. Ora a métrica aqui apresentada é o parâmetro *N* do algoritmo TCSC descrito anteriormente.

Relembremos o funcionamento e a execução desse algoritmo:

No algoritmo TCSC é analisado e investigado cada segmento de 3s do ECG. Cada segmento é multiplicado por uma janela definida como:

$$w(t) = \begin{cases} 0.5(1 - \cos(4\pi t)), & 0 \leq t \leq \frac{1}{4} \\ 1, & \frac{1}{4} \leq t \leq L_s - \frac{1}{4} \\ 0.5(1 - \cos(4\pi t)), & L_s - \frac{1}{4} \leq t \leq L_s \end{cases}, \quad \text{sendo } L_s \text{ o segmento de 3s.}$$

Em termos práticos, para conseguir desenvolver esta janela e analisar os sucessivos segmentos de 3-s criamos uma função no *MATLAB* que ficou com o nome de *TCSCjan*. Pretende-se no início que esta função tenha a capacidade de extrair, da porção de ECG que estamos a analisar, sucessivos segmentos de 3-s com 1-s de diferença entre eles. Isto é cada segmento tem 2-s de sobreposição com outro que equivale a cerca de 66%.

O passo seguinte, segundo este algoritmo, é de multiplicar cada segmento de 3-s anteriormente extraído pela janela  $w(t)$  descrita em cima. Na prática estamos a trabalhar com um sinal digital e o tempo não é contínuo, mas sim discreto pelo que teremos que considerar a frequência de amostragem ( $fa$ ). Assim  $\frac{1}{4}$  de segundo correspondem a  $\frac{1}{4} \times fa$  amostras do sinal enquanto que o vetor  $t$  no  $\cos(4\pi t)$  é discreto pelo que corresponde a  $n/fa$ , sendo  $n$  a amostra a que se está a percorrer. No final cada segmento é normalizado, dividindo o mesmo pelo seu valor máximo.

Por fim guardamos todos estes segmentos numa matriz em que cada coluna corresponde a um segmento de 3-s, sendo o número de linhas representativas da quantidade de amostras de cada segmento ( $3fa = 750$  amostras). Como cada porção do ECG analisado possui 10000 amostras correspondentes a 40 s, então a matriz obtida terá  $(40 - 2)$  colunas devido à sobreposição de 2-s das janelas elaboradas.

Apresenta-se na figura 17 o resultado da multiplicação desta janela ao nosso segmento de 3-s.

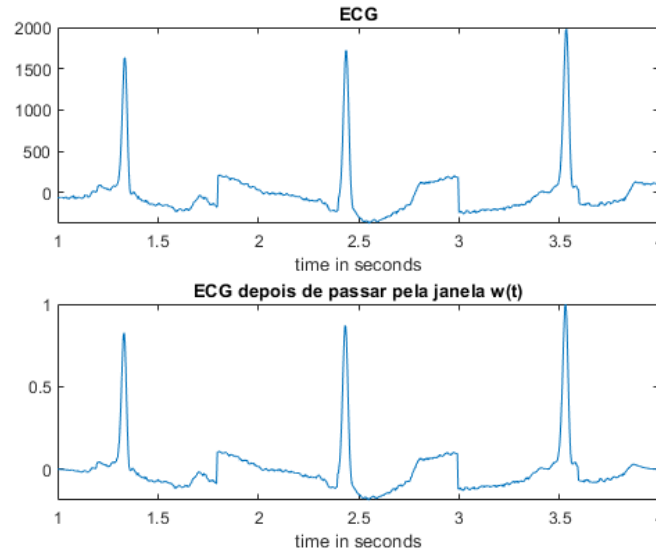


Figura 13-Efeito da utilização da janela  $w(t)$  sobre o primeiro segmento de ritmo sinusal para o paciente 1 (cu01).

O próximo passo é a conversão deste segmento obtido em binário. Ou seja, sempre que uma amostra do nosso sinal passar um certo limite ( $V0$ ) essa amostra ficará com o valor de 1, pelo contrário se não ultrapassar esse limite a amostra ficará com o valor de 0. Segundo o artigo [8] o valor do limite que se obtém melhores resultados é de 0.2 e deve ser fixado tanto para a parte positiva como para a parte negativa do eixo das ordenadas (-0.2). De modo a conseguir transferir isto para o nosso trabalho criou-se uma função *TCSCconvert\_binary* que irá converter cada um dos 38 segmentos em sinais binários. Para a elaboração desta função utilizou-se 2 ciclos *for*, o primeiro percorre cada segmento do sinal e o segundo percorre cada amostra desse mesmo segmento. Assim se a amostra do segmento ultrapassar 0.2 damos o valor 1 à mesma, caso contrário o valor 0. Por fim guardámos o novo sinal binário numa matriz *ecgbin* e calculámos a métrica denominada  $N(\%)$  que não é nada mais que a percentagem de amostras que ultrapassam o limite  $V0$  para cada segmento. O cálculo de  $N(\%)$  foi bastante fácil já que o sinal só possui dois valores (0 e 1), em que sempre que ocorre o número 1 quer dizer que essa amostra ultrapassou o tal limite, então utilizou-se o comando *sum* sobre a matriz e obteve-se o número de amostras que atravessavam o limite. De seguida dividiu-se esse número pelo número total de amostras e multiplicou-se por 100 para ter a percentagem. Segue-se nas figuras uma exemplificação do funcionamento desta métrica bem como a conversão dos sinais em binários.

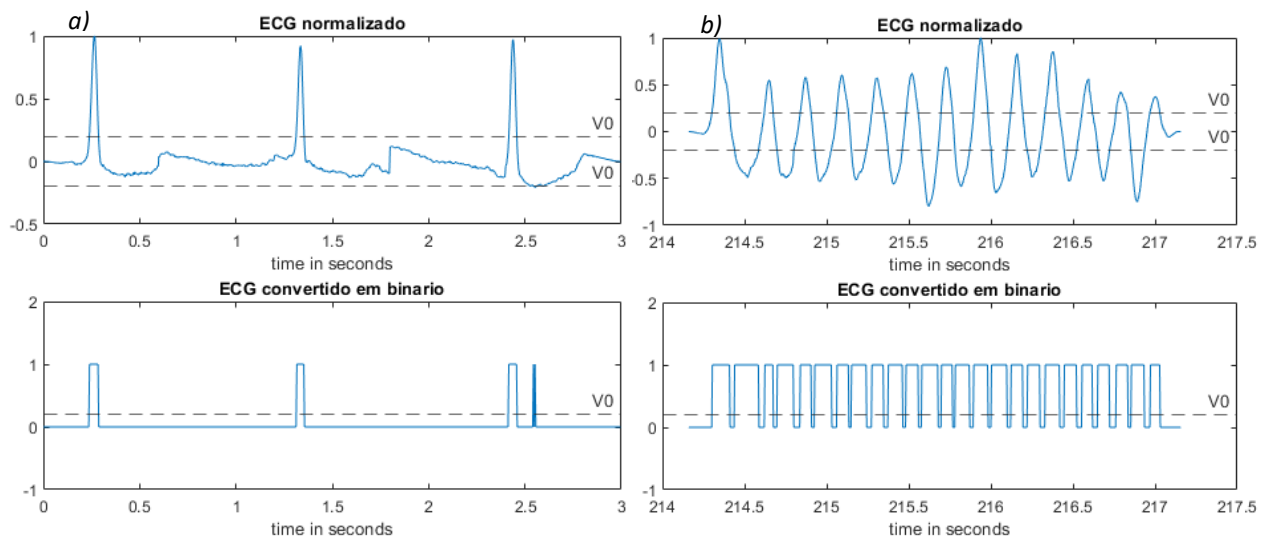


Figura 14- Conversão de um segmento ECG normalizado com ritmo sinusal (a) e com fibrilação ventricular (b) em binário após passagem pelo limite  $V0$  para o paciente 1 (cu01)

Através da figura 18 podemos observar claramente a diferença entre o ritmo cardíaco sinusal e o ritmo que apresenta fibrilação ventricular. Na figura 18(a) onde se apresenta um batimento cardíaco sem nenhuma anomalia podemos verificar que o sinal binário é pouco expressivo e que escassas são as amostras que passam o limite estipulado. Pelo contrário na figura 18(b), quando ocorre fibrilação, o sinal binário é muito evidente e a maioria das amostras ultrapassam  $V0$ . Com isto, é fácil de perceber que a métrica  $N(\%)$  deve ser bastante superior quando ocorre fibrilação ventricular.

Finalmente, guardamos os 38 valores da métrica  $N(\%)$  numa matriz e não seguimos à regra o algoritmo exposto na literatura já que pretendemos elaborar o nosso próprio projeto e avaliar a força desta própria métrica.

Salienta-se que procedemos da mesma forma para todos os pacientes e tanto para a sua parte do ECG com a patologia e sem a própria.

## 2.2.5 F1 ratio

A última métrica utilizada é talvez a mais atípica e menos comum comparativamente às métricas descritas anteriormente.

Como abordado no capítulo 1 esta métrica baseia-se na extração de características a partir de dois gráficos elaborados através do ECG.

Na primeira etapa desenvolve-se um primeiro gráfico em que a sua abcissa(x) são as amostras do ECG analisado ( $s_1, s_2, s_3, \dots, s_i$ ) e as ordenadas(y) são as mesmas amostras adiantadas de uma amostra ( $s_2, s_3, s_4, s_{i+1}$ ). A elaboração do segundo gráfico é bastante semelhante ao primeiro, no entanto, para este último colocámos um adiantamento de 5 amostras nas ordenadas ( $s_{i+5}$ ) comparativamente às abcissas.

O desenvolvimento deste tipo de gráficos é bastante peculiar, porém, podemos observar características bastante interessantes a partir dos mesmos. Como procedemos até este momento para todas as outras métricas, fizemos estes 2 gráficos para as duas porções do ECG que nos interessa estudar (fibrilação ventricular ou não). Mostrámos de seguida as figuras 19 e 20 obtidas para ambos os casos no paciente 1, onde tudo foi elaborado em *Matlab*:

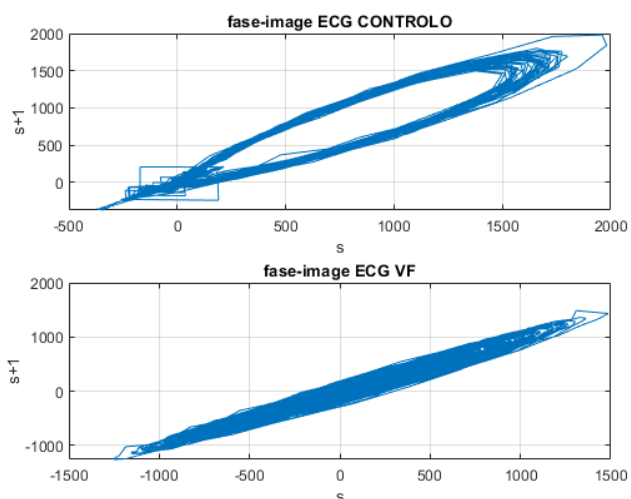


Figura 19-Gráficos do ECG do paciente 1 com as ordenadas adiantadas de 1 amostra relativamente às abcissas.

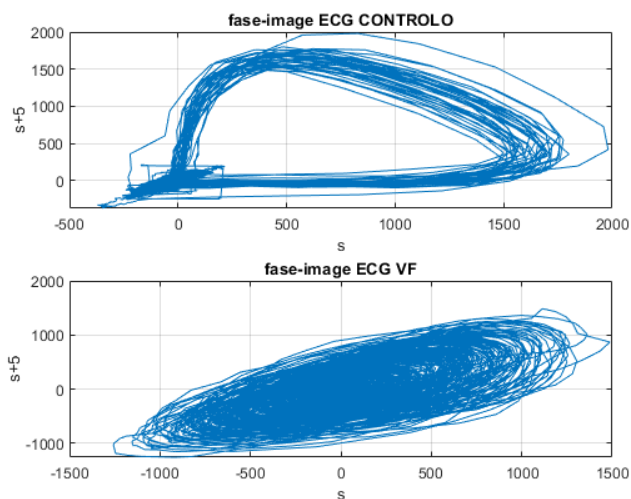


Figura 20- Gráficos do ECG do paciente 1 com as ordenadas adiantadas de 5 amostras relativamente às abcissas.

Desde já conseguimos averiguar que estas duas figuras exprimem aspetos bastante interessantes. Primeiramente, através da observação das duas figuras como um todo somos capazes de reparar em diferenças bastante evidentes no que diz respeito à distinção entre o ECG que apresenta fibrilação ventricular daquele que não apresenta. Assim, conseguimos verificar

que as linhas do gráfico do ECG com fibrilação estão mais densas e juntas, enquanto pelo contrário o ECG sinusal apresenta linhas mais separadas estando sem densidade de linhas na zona central. Além disso podemos observar que a figura 20 apresenta linhas mais afastadas do que a figura 19 sugerindo assim que quanto maior o adiantamento das amostras, maior o afastamento das linhas.

Com isto, a métrica aqui representada baseia-se na extração de características destes gráficos, pelo que de maneira a facilitar o seu estudo é sugerida a conversão destas figuras em imagens binárias como nova etapa deste método. Na prática criámos uma função *convert\_graph\_to\_binary* que possui como parâmetro de entrada o ECG a analisar e como saída a métrica *F1* pretendida. Em primeiro lugar, gerámos as duas figuras demonstradas previamente e guardamos em 2 variáveis distintas (*fig1*, *fig2*). De seguida usamos a função *getframe* do *Matlab* e também a *frame2im* sobre as duas figuras, de modo a converter as figuras em imagens. Isto tudo é feito para depois possibilitar a conversão através da função *im2bw* das imagens em imagens binárias. Esta conversão em imagem binária é extremamente útil porque é uma forma eficaz e fácil de poder calcular e avaliar a densidade ou concentrações de pixéis para cada imagem, de modo a quantificar as observações feitas anteriormente. Assim a função *im2bw* irá criar uma matriz com dimensão de  $[CxL]$  que contem apenas os valores de 1 e 0 corresponde ao pixéis brancos e aos pixéis pretos, respetivamente. Nós estamos interessados em saber a fração de pixéis pretos em relação ao número total de pixéis da imagem de modo a podermos contabilizar a densidade dos pixéis. Assim, utilizámos a função *find()* com *~* sobre a matriz devolvida pela função *im2bw* de modo a encontrar os zeros da matriz. Seguidamente com a função *length* descobrimos a quantidade de pixéis pretos e dividimos pela quantidade total de pixéis. Este processo foi desenvolvido para os dois gráficos (1 e 5 amostras adiantadas) e descobrimos então o ratio de pixéis pretos para cada um deles. Com isto, a métrica *F1* é obtida através da subtração do ratio de pixéis pretos para o gráfico com 5 amostras adiantadas (ratio 2) pelo ratio de pixéis pretos para o gráfico que apresenta 1 amostra adiantada (ratio 1).

Segue-se em baixo exemplos ilustrativos do resultado da conversão das figuras em imagens binárias.




Figura 21—Conversão em binário dos gráficos do ECG sinusal do paciente 1 com as ordenadas adiantadas de 5 amostras relativamente às abcissas.




Figura 22- Conversão em binário dos gráficos do ECG com fibrilação do paciente 1 com as ordenadas adiantadas de 5 amostras relativamente às abcissas.

Através da observação destas imagens voltamos novamente a ter a perceção que zonas do ECG que apresentam fibrilação ventricular são mais densas. Assim espera-se que a métrica *F1* seja maior para zonas de fibrilação.

Como para todo o nosso projeto elaboramos novamente esta métrica para todos os pacientes. Os resultados mais evidentes serão novamente discutidos mais tarde quando introduzirmos as janelas efetuadas para o cálculo destas métricas.



## 2.3 Escolha da janela adequada para cálculo das métricas

Até agora todas as métricas descritas e as figuras apresentadas (à exceção da  $N(\%)$ ) foram calculadas e obtidas analisando o segmento pré-selecionado de 10000 amostras(40s) como um todo para os dois casos de ECG já mencionados. No entanto adotamos outra estratégia para conseguirmos ter uma percepção da evolução da métrica ao longo do tempo e poder efetuar um cálculo mais preciso e rigoroso das mesmas.

Durante a análise de sinais temos a necessidade de fazer truncamentos aos próprios subdividindo os sinais em fragmentos. Esta necessidade surge devido a diversos fatores como: diminuição do efeito de ruído nas fronteiras dos limites do nosso sinal, fornecimento de maior informação quanto à evolução do sinal e possibilidade de redução do efeito de *leakage*[15]. Além disso esses fragmentos(janelas) podem muitas vezes apresentar sobreposição entre eles, ou seja, cada janela poderá ter um conjunto de amostras que já pertencem ao segmento anterior. A sobreposição de janelas permite uma redução da perda de informação nas fronteiras de cada janela.

Deste modo criamos janelas com 50% de sobreposição que permitem fragmentar o sinal e calcular para cada fragmento as respectivas métricas descritas nas seções anteriores. Quanto ao tamanho das próprias ocorreu uma indecisão entre os 7.5 s e os 10 s. Estes valores surgiram devido a que o segmento apresenta 40s, logo, de modo a não tornar o nosso algoritmo muito pesado e exigente computacionalmente pretendíamos obter um número relativamente baixo de janelas e que compreendesse alguns batimentos cardíacos. Assim optamos por elaborar janelas de 10 s que apresenta cada uma delas cerca de 9 batimentos cardíacos. A razão para a rejeição da janela de 7.5s é o facto de esta apresentar alguns problemas na sua extração e cálculo nomeadamente a necessidade de arredondamento de decimais a inteiros. De seguida apresenta-se um exemplo ilustrativo da construção das janelas.

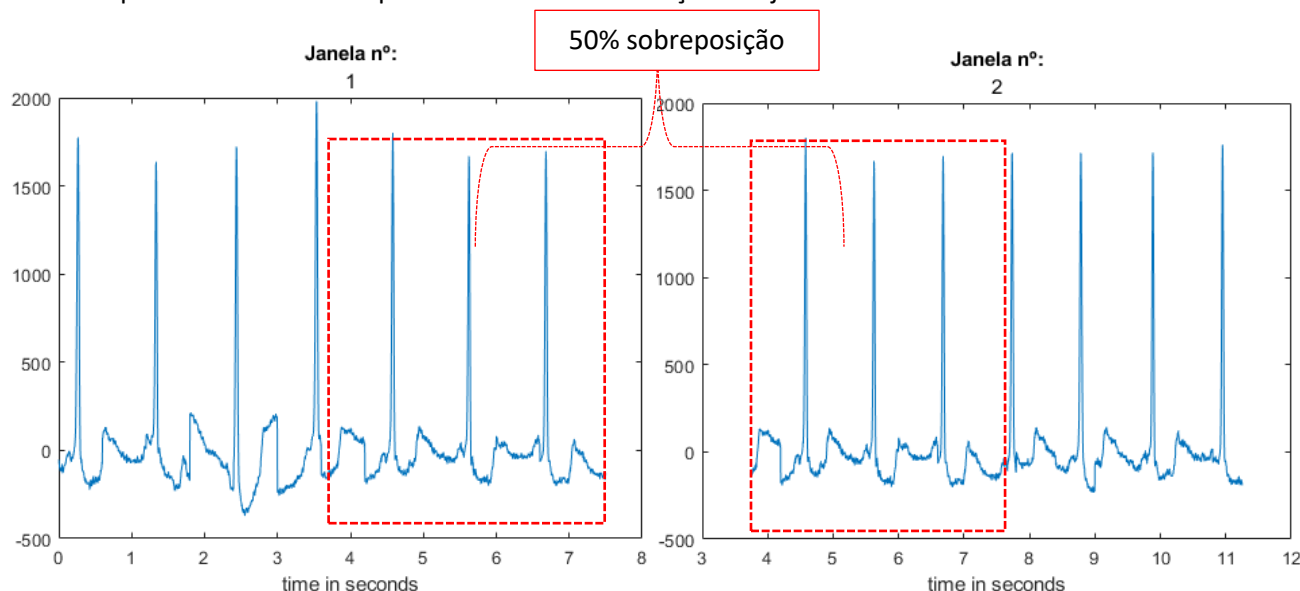


Figura 23-Exemplo da construção de janelas para o ECG sem fibrilação ventricular para o paciente 1(cu01)

Depois da construção das janelas referidas anteriormente criamos uma função *janelas()* onde colocámos no seu interior todo o código elaborado para extração das métricas descritas nas subseções anteriores. No entanto, não colocámos a métrica  $N(\%)$  pois a própria já é constituída através de janelas específicas como mencionado anteriormente. Assim criamos matrizes para cada métrica (frequência média, potência, frequência fundamental e F1) em que o número de colunas é o número de janelas (7) nas quais estas métricas foram calculadas. Com

isto, a função *janelas* tem como parâmetros de entrada o segmento ECG a ser analisado, a frequência de amostragem e o tempo de cada janela em segundos (caso pretendemos mudar). Os parâmetros de saída são as respectivas métricas calculadas com as características matriciais referidas.

Em seguida iremos recorrer à análise das métricas nesta nova perspectiva de modo a avaliar e perceber como as mesmas evoluem ao longo do tempo para ECG's com e sem fibrilação ventricular. Além disso produziu-se um *boxplot* para cada paciente através do qual se tornou mais fácil a visualização dos resultados obtidos para as métricas efetuadas.

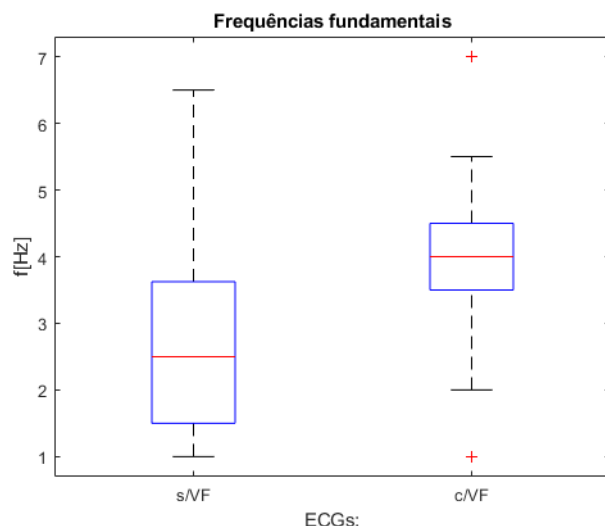
As *boxplots*[16] ou caixa de bigodes são uma ferramenta gráfica que permite observar a variação e distribuição dos nossos dados. Esta ferramenta fornece-nos várias medidas estatísticas importantes para análise das nossas métricas como o primeiro quartil, mediana, terceiro quartil, o máximo, mínimo e os *outliers*. Um fator interessante da caixa de bigodes é o facto de ele excluir valores discrepantes dos nossos dados(*outliers*) no cálculo das medidas estatísticas referidas anteriormente.

Além disso, para cada métrica, apresentaremos o resultado de um teste de hipótese de modo a corroborar com o *boxplot* constituído. Os testes de hipóteses são testes de decisão efetuados com o objetivo de rejeitar ou não uma hipótese estatística com base em elementos amostrais[17]. Como no nosso caso, temos duas populações (fibrilação e não fibrilação) em que cada elemento de uma amostra tem o seu corresponde na outra amostra, elaboramos um teste de hipóteses emparelhados, *Wilcoxon signed rank test*[18] em *MATLAB*. Este teste pressupõe, a hipótese nula( $H_0$ ) como a diferença entre as medianas das duas amostras emparelhadas ser 0 com um nível de significância de 5% ( $\alpha$ ). Assim, o nosso objetivo é rejeitar esta hipótese nula para concluir que de facto há diferenças entre os valores de cada métrica para ambas as condições do ECG. Depois de elaborar o teste numa plataforma computacional os resultados são obtidos a partir da análise do *p-value*. O *p-value* pode ser visto como o menor nível de significância com que se rejeita  $H_0$ . Assim, caso o *p-value* seja menor que  $\alpha$ , pode se rejeitar a hipótese nula, caso contrário não se rejeita a mesma.

### 2.3.1 Frequência Fundamental

Como referido no início deste capítulo foram extraídas para cada paciente duas porções do ECG, em que numa delas presenciava-se um episódio de fibrilação ventricular e outra não. Assim para cada porção foram calculadas as métricas referidas. Como cada porção é percorrida pelas 7 janelas mencionadas previamente e as métricas são calculadas para cada janela, cada métrica possui 7 valores para cada porção de ECG. Deste modo, com o objetivo de perceber e comparar as diferenças reveladas pelas respetivas métricas entre as duas condições cardíacas construiu-se 2 *boxplots* comparativos para cada métrica e cada paciente. No entanto, nem todos os pacientes apresentam exatamente as mesmas características para cada métrica pois a mesma está associada à fisiologia de cada paciente.

Assim, para melhor avaliar este efeito extraíram-se as medianas para cada métrica nas duas condições cardíacas em todos os pacientes e elaborou-se um *boxplot* comparativo para esses valores. No anexo A, tabela 12 podemos ver o valor das métricas para cada paciente. Deste modo, para as próximas métricas apresentaremos apenas este *boxplot* pois é aquele que permite tirar conclusões gerais. Com isto, apresenta-se de seguida os resultados obtidos para a frequência fundamental:



Métrica	Freq.Fund.
P-value	0.0079

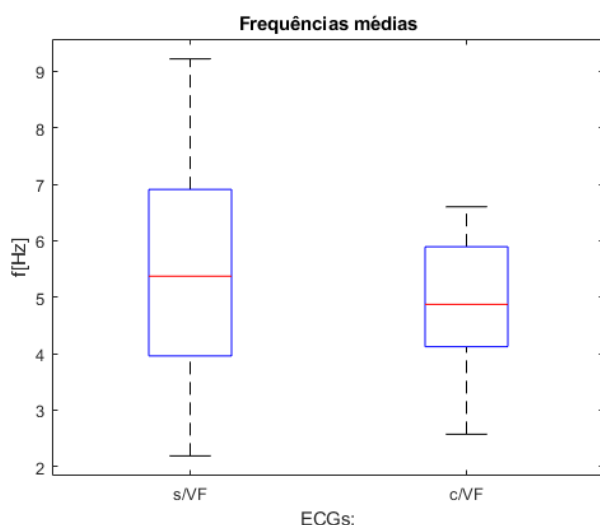
Tabela 4-Resultados do teste de hipóteses elaborado para a métrica da frequência fundamental.

Figura 24-Boxplot contruído através das medianas para todos os pacientes da métrica Frequências Fundamentais.

A partir da figura 24 concluímos que as frequências fundamentais são maiores para zonas de fibrilação. Além disso podemos verificar que as frequências fundamentais se encontram, maioritariamente, numa gama de valores entre 3.5 e 4.5 Hz com base nos quartis e apresenta uma mediana de 4 Hz para zonas de fibrilação. Por outro lado, nos ECG's que não possuem a anomalia, os valores da métrica estão compreendidos entre 1.5 e 3.6 Hz com uma mediana de 2.5 Hz. Além disso pela tabela 4 o  $p$ -value é de 0.0079 que é menor que 0.05 ( $\alpha$ ), pelo que todas as afirmações anteriores são corroboradas pelo teste de hipóteses que anula a hipótese das medianas para as duas condições serem iguais.

### 2.3.2 Frequência Média

A próxima métrica a ser avaliada é a frequência média. Todo o procedimento para a métrica anterior foi repetido para este novo caso. Deste modo, tal como na métrica anterior apresentamos o *boxplot* construído com as medianas de todos os pacientes para avaliar melhor a situação.



Métrica	Freq.Med
P-value	0.1578

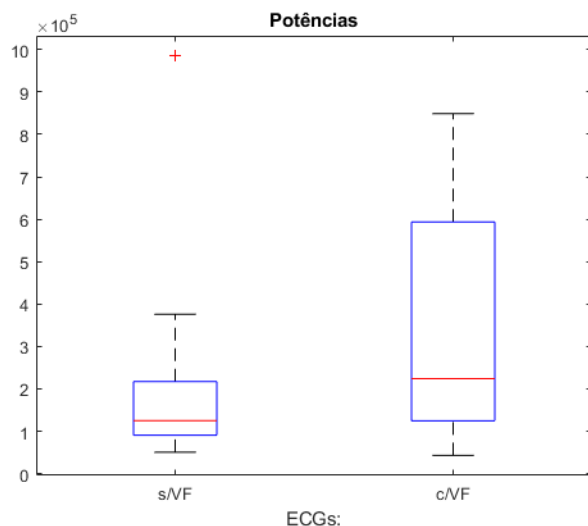
Tabela 5- Resultados do teste de hipóteses elaborado para a métrica da frequência média.

Figura 25- Boxplot contruído através das medianas para todos os pacientes da métrica frequências médias.

A partir da análise da figura 25 é bastante notório a grande sobreposição dos valores apresentados para a frequência média nas diferentes zonas estudadas. O comportamento exibido para esta métrica ao longo dos pacientes não permite verificar se, de facto, as frequências médias revelam-se mais elevadas ou não para zonas de fibrilação. Analisando o teste de hipóteses, através da tabela 5 obtivemos um *p-value* maior que 0.05 pelo que não conseguimos rejeitar a hipótese de as medianas serem iguais. Assim, conclui-se que não é possível encontrar um comportamento padrão para esta métrica e não é adequada para a discriminação pelo que não será mais usada neste projeto.

### 2.3.3 Potência

A terceira métrica estudada é a potência, seguindo-se para a sua avaliação novamente os mesmos passos que as métricas anteriores. Com isto apresenta-se o *boxplot* contruído com os dados de todos os pacientes.



Métrica	Potência
P-value	0.0370

Tabela 6- Resultados do teste de hipóteses elaborado para a métrica da potência.

Figura 26- Boxplot contruído através das medianas para todos os pacientes da métrica da potência.

A análise da figura 26 permite afirmar que esta métrica não tem um comportamento tão linear como pretendido, aliás ainda apresenta bastante sobreposição para as duas condições aqui estudadas. Ainda assim consegue-se verificar que o ECG com fibrilação apresenta um número considerável de valores bastante mais elevados para a potência comparativamente à outra condição. Através do valor do *p-value* da tabela 6 verificámos que o mesmo é menor que 0.05 pelo que o nosso teste de hipóteses rejeitou a hipótese das medianas serem iguais. Concluimos assim que, embora esta métrica não pareça extremamente apropriada para o processo de discriminação da patologia, poderá dar um certo auxílio nesta tarefa.

### 2.3.4 N(%)

A seguinte métrica a ser explorada é a  $N(\%)$ . Como as restantes métricas até agora revela-se o *boxplot* comparativo conseguido pela avaliação de todos os pacientes:

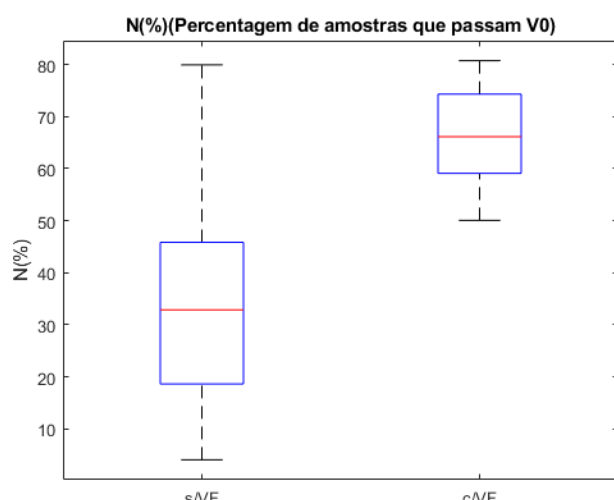


Figura 27- Boxplot contruído através das medianas para todos os pacientes da métrica da  $N(\%)$ .

Métrica	$N(\%)$
P-value	5.75e-5

Tabela 7-- Resultados do teste de hipóteses elaborado para a métrica  $N(\%)$ .

Como seria de esperar, a observação da figura 27 revelou que o valor da  $N(\%)$  é muito maior para zonas de fibrilação e não ocorre sobreposição. Estas conclusões eram previsíveis já que em episódios de fibrilação ventricular o sinal apresenta muitas oscilações pelo que é normal que o número de amostras que passam o limite  $V0$  seja maior comparativamente com um ritmo cardíaco sinusal. Através da tabela 7 podemos verificar que o  $p$ -value é muito menor que 0.05 pelo que muito provavelmente as medianas não são iguais para as duas condições cardíacas.

Com isto, podemos concluir que esta métrica se pode revelar muito interessante no processo de discriminação da patologia cardíaca.

### 2.3.5 F1 ratio

A próxima métrica a ser analisada é a  $F1$  segundo os mesmos processos descritos. Assim apresenta-se de seguida o *boxplot* permite avaliar esta métrica:

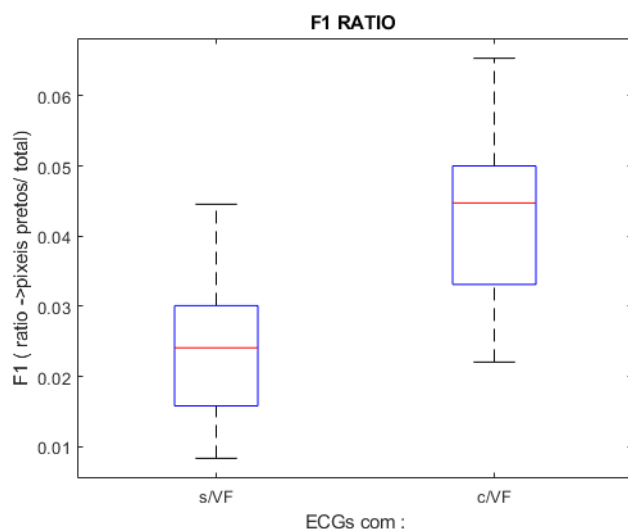


Figura 28- Boxplot contruído através das medianas para todos os pacientes da métrica da  $F1$  ratio.

Métrica	F1 ratio
P-value	3.22e-5

Tabela 8- Resultados do teste de hipóteses elaborado para a métrica  $F1$  ratio.

Com a análise da figura 28 podemos aferir que não há praticamente sobreposição de valores entre ECG's com e sem fibrilação ventricular. Através da tabela 8 podemos verificar que o teste de hipóteses corrobora a afirmação anterior já que o *p-value* é muito menor que 0.05, significando que as medianas são diferentes para as duas condições. Com isto, conclui-se que, as métricas *N(%)* e *F1* podem-se revelar de extrema importância para o objetivo primordial deste projeto, uma vez que têm o *p-value* mais baixo comparativamente às restantes.

## Pequena retrospectiva

Métrica	Freq.Fund.	Freq.Med	Potência	N(%)	F1 Ratio
P-value	0.0079	0.1578	0.0370	5.75e-5	3.22e-5

Tabela 9-Resultados do teste de hipóteses para todas as métricas

Através da análise da tabela 9 é possível verificar que a única métrica em que o *p-value* é maior que  $\alpha$  é a frequência média. Deste modo, descartamos esta métrica e não vai ser usada no processo de classificação. A situação é precisamente contrária para as outras quatro métricas em que o *p-value* foi sempre menor que 0.05( $\alpha$ ). No entanto quanto menor o *p-value*, melhor e, portanto, podemos estabelecer uma hierarquia das métricas que serão mais favoráveis para a discriminação. Assim com uma ordem decrescente de mais valia temos a seguinte sequência: *F1*, *N (%)*, *Frequência Fundamental* e *Potência*. Conclui-se assim que todas as métricas com exceção à frequência média seguem para o processo de classificação onde também vamos avaliar quais as métricas mais influentes e importantes para discriminação da condição cardíaca.

## 2.4 Classificação

Todo o processo e algoritmo elaborado até esta seção teve como objetivo escolher, avaliar e averiguar quais as métricas adequadas no processo de discriminação entre a fibrilação ventricular e não presença desta anomalia cardíaca. Nesta fase já sabemos que de entre todas as métricas escolhidas a frequência média é aquela que não avança para a classificação já que, como visto pelo teste de hipóteses, não cumpre os requisitos.

Deste modo e obtidas estas métricas, seguimos duas diferentes abordagens para a desejada classificação destas porções do ECG: *Unsupervised* e *Supervised Learning*.

Nesta seção iremos explicitar cada um deles separadamente.

### 2.4.1 Unsupervised Learning

*Unsupervised learning*[19] é uma forma de aprendizagem automática onde não há necessidade do modelo saber a respetiva classificação dos nossos dados. O objetivo desta aprendizagem é o próprio modelo inferir uma estrutura natural da nossa base de dados. A maioria dos modelos realiza isto utilizando uma técnica denominada “clustering” que não é nada mais que agrupar os nossos dados de acordo com as suas semelhanças. No nosso caso específico queremos que este modelo consiga agrupar por si só os segmentos de ECG que possuem fibrilação em separado dos ECG's que não possuem fibrilação.

Primeiramente, agrupamos o conjunto das nossas métricas numa matriz com dimensão de [50x4]. As 4 colunas dizem respeito à métrica associada e cada linha representa a respetiva porção do ECG. Como o nosso estudo é efetuado para 25 participantes e cada participante apresenta 2 segmentos de ECG, logo obtemos 50 segmentos correspondentes às respetivas

linhas. É de salientar que o valor das métricas corresponde à mediana extraída dos *boxplots* construídos para cada paciente nos respetivos segmentos de VF e não VF.

Assim utilizou-se o modelo de *K-means* no MATLAB com a respetiva referência da existência de 2 grupos na nossa base de dados. Inicialmente a nossa base de dados irá possuir todas as métricas, no entanto temos como futuro objetivo verificar a influência de cada uma das métricas e respetiva força na discriminação da condição de patologia. Convém salientar que neste caso recorremos à normalização das métricas através da fórmula de *Min-Max Scaling*[16]:

$$x' = \frac{x - x_{min}}{x_{max} - x_{min}} \quad (7)$$

Este requisito surge do facto de que o modelo *K-means* funcionar calculando distâncias euclidianas entre os nossos pontos (dados). Deste modo é fácil de perceber que se uma certa métrica tem um valor de uma ordem de grandeza muito diferente das outras irá influenciar negativamente nos nossos resultados. Neste trabalho verificámos literalmente isso para o caso da *potência* devido a esta possuir uma ordem de grandeza muito superior às outras métricas.

Deste modo e também com a ambição de estudar a influência de cada uma das métricas, variámos a nossa base de dados retirando por vezes uma ou duas métricas de modo a avaliar o impacto de cada uma delas na distinção dos grupos. No *Matlab* utilizamos uma função que permite avaliar os nossos resultados, tendo em conta os verdadeiros positivos (TP), falsos positivos (FP), verdadeiros negativos (TN) e falsos negativos (FN). Segue como exemplo ilustrativo um resultado devolvido pela nossa função.

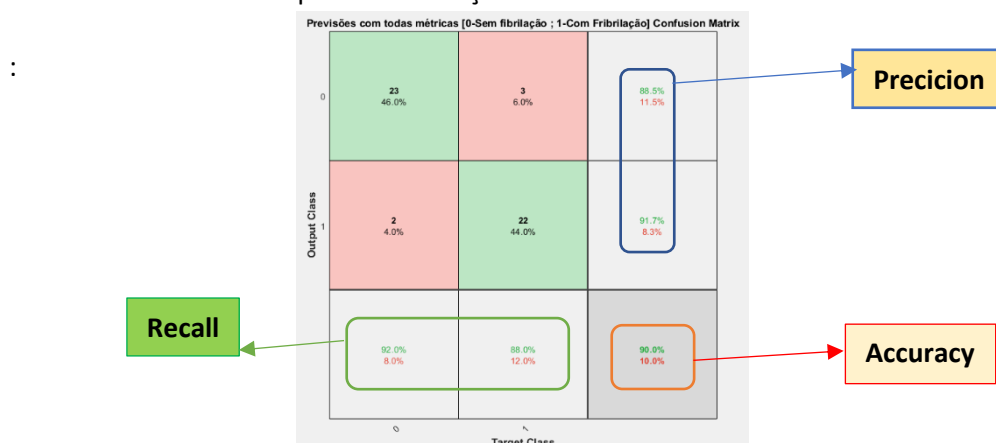


Figura 29-Matriz de confusão para o modelo *k-means* quando utilizamos todas as métricas

Antes de mais, e com o objetivo de fazer uma análise mais quantitativa, é importante introduzir dois conceitos importantes relativamente à avaliação de resultados quando se trabalha com modelos de aprendizagem automática. Um desses conceitos é apelidado como *accuracy* que é nada mais que a percentagem que o nosso modelo foi capaz de acertar relativamente a todas as previsões possíveis. No entanto, outro conceito bastante importante e que é particularmente relevante para o nosso objetivo neste projeto é a *sensibilidade*. Isto porque a *sensibilidade* transmite-nos qual é a percentagem de positivos que o nosso modelo previu corretamente, sendo o positivo, o ECG com fibrilhação, já que é aquele que pretendemos prever. Neste género de casos clínicos é mais importante para o nosso modelo acertar sempre que um paciente tenha fibrilhação de modo a poder prevenir e recorrer a desfibrilhação do que o contrário.

Com isto, no próximo capítulo apresentaremos os resultados tendo em conta estes critérios em cima introduzidos.

## 2.4.2 Supervised Learning

Ao contrário do *unsupervised Learning* quando utilizamos *supervised learning* nós sabemos à partida qual será a saída do nosso conjunto de dados. O objetivo desta aprendizagem, será encontrar uma função e uma relação entre o conjunto das métricas e a saída desejada. No nosso caso pretendemos que este método computacional permita encontrar uma relação que relaciona cada conjunto das quatro métricas selecionadas com a respetiva correspondência ao estado do ECG (fibrilação ventricular ou não).

Com isto utilizou-se o modelo *random forest* [20] através do servidor do *Kaggle* em linguagem *python*. Ao contrário do *unsupervised learning*, neste caso trabalhamos com as métricas não normalizadas. Isto deve-se ao facto de que, na sua génese, o modelo *random forest* funcionar a partir de um conjunto de árvores de decisões e seguindo um conjunto de regras para cada métrica em separado, pelo que não será sensível à normalização dos nossos dados.

Deste modo, agrupamos o conjunto das nossas métricas bem como a sua respetiva classificação num ficheiro com formato *.csv*. As colunas dizem respeito à métrica associada e cada linha representa a respetiva porção do ECG. A última coluna refere a classificação da porção do ECG como fibrilação (1) ou não fibrilação (0).

Todo o código e importação do modelo selecionado foi elaborado em *python*. Convém salientar que sempre que o código é corrido os dados de treino e validação são escolhidos aleatoriamente. Além disso das 50 porções de ECG analisado, o programa seleciona 37 como treino e os 13 restantes como validação e os resultados apresentados no próximo capítulo referem-se aos dados de validação. Por este motivo, cada vez que iniciamos o nosso classificador vamos obter um resultado de classificação diferente. Com o objetivo de melhor avaliarmos os nossos resultados, adotámos a estratégia de correr o nosso classificador 15 vezes e registar a média e respetivo desvio padrão dos resultados obtidos. Apresenta-se de seguida 2 exemplos demonstrativos relativos à matriz de confusão devolvida pelo algoritmo utilizado em *python*.




Figura 30-Resultados obtidos para a primeira utilização(a) e segunda utilização (b) do modelo de *random forest* quando utilizámos todas as métricas

Além disso deixámos aqui algumas fórmulas utilizadas para a avaliação dos resultados através da matriz de confusão:

$$Accuracy = \frac{TP+TN}{TP+FP+TN+FN} \quad (8)$$

$$Sensibilidade = \frac{TP}{TP+FN} \quad (9)$$

$$Precision = \frac{TP}{TP+FP} \quad (10)$$

$$Especificidade = \frac{TN}{TN+FP} \quad (11)$$



### 3 Resultados e discussão

Após elaboração do algoritmo proposto conseguimos extrair, escolher e averiguar quais as métricas que, teoricamente, serão mais vantajosas e úteis na discriminação entre o ritmo sinusal e a patologia de Fibrilação Ventricular.

Deste modo e obtidas estas métricas, seguimos duas diferentes abordagens para a desejada classificação destas porções do ECG: *Unsupervised* e *Supervised Learning* como relatado no capítulo anterior.

Assim, neste capítulo, apresentamos os resultados obtidos, bem como a respetiva discussão dos mesmos.

#### 3.1 Unsupervised Learning

Como explicitado no capítulo anterior variamos a nossa base de dados de modo a avaliar a importância de cada métrica. Com isto obtivemos os seguintes resultados para a classificação representados na tabela 10.

	4 métricas	Sem potência	Sem FF	F1 e N(%)	FF e N(%)	Apenas N(%)
<b>Accuracy</b>	0.90	0.90	0.76	0.88	0.86	0.88
<b>Sensibilidade</b>	0.88	0.88	0.60	1	0.96	1
<b>Precision</b>	0.917	0.917	0.882	0.806	0.80	0.806
<b>Especificidade</b>	0.92	0.92	0.92	0.76	0.76	0.76

Tabela 10- Resultados para o uso do modelo k-means em unsupervised learning. Nota: FF-frequência fundamental

A partir da análise da tabela 10 em cima apresentada verificámos logo à primeira vista que a *potência* é completamente irrelevante como métrica quando as outras três métricas estão presentes para ajudar na formação dos grupos. Pelo contrário quando retirámos apenas as *Frequências Fundamentais*, os resultados são muito piores pelo que podemos inferir que as *Frequências Fundamentais* (FF) são mais importantes e discriminatórias do que a *potência*. Esta averiguação corrobora com o teste de hipóteses anteriormente elaborado. Por sua vez, podemos verificar que, além da *potência* ser irrelevante para esta classificação, também influencia negativamente nos resultados caso a FF não está presente.

Com isto e partindo então para uma análise mais quantitativa, é possível verificar que, quanto à *accuracy* obtivemos um melhor resultado quando utilizámos as 3 métricas (F1, N(%), frequências fundamentais) de 90 %, do que quando retiramos as *frequências fundamentais* (F1, N(%)), apresentando-se uma *accuracy* de 88%. Concluimos assim que as *frequências fundamentais* influenciam positivamente nos resultados globais quando esta está presente em conjunto com a F1 e N(%).

Ainda assim verificámos que a *frequência fundamental* influencia negativamente no resultado quando apenas utilizamos 2 métricas já que, tanto a *accuracy* como a *sensibilidade* baixaram os seus valores quando colocamos as *frequências fundamentais* em conjunto com a N (%) e em detrimento da métrica F1. Mesmo assim utilizando apenas as 2 métricas (F1 e N) temos uma *sensibilidade* de 100%. Ainda, apenas utilizando a métrica N(%) temos exatamente os mesmos resultados. Concluimos assim que a métrica N(%) é a mais influente, predominante e que prevê melhor na distinção entre o ritmo sinusal e fibrilação. Com este estudo verificamos ainda que F1 não influencia nos resultados quando está em conjunto com a N(%).

Finalmente, concluimos que podemos optar por duas soluções distintas. Por um lado se pretendemos um maior acerto em todas as previsões possíveis, ou seja, uma maior *accuracy*, a

utilização das métricas  $N(\%)$ ,  $F1$  e  $FF$  em conjunto é a melhor opção com uma percentagem de 90%. Por outro lado, se utilizarmos a métrica  $N(\%)$  isolada diminuíamos a *accuracy* do nosso modelo em 2%, mas obteríamos uma *sensibilidade* de 100% quanto à deteção de fibrilação ventricular em contraste com os 88% aquando do uso das 3 métricas em conjunto anteriormente referidas. Assim e fazendo um balanço geral o facto de apenas ser necessário uma métrica e ter 100% de acertos relativamente à existência de fibrilação ventricular, que, de certa forma é o mais importante, leva-nos a ponderar a utilização desta última opção neste tipo de modelo pelo facto de ser mais eficiente e rápido em termos computacionais.

### 3.2 Supervised Learning

Como averiguamos anteriormente na subsecção dos resultados do *unsupervised learning* e que está de acordo também com o teste de hipóteses elaborado, a *potência* é a métrica que tem menor poder de discriminação da condição. Com isto, também apresentamos os resultados da nossa classificação com e sem esta métrica para ver qual a influência nesta nova abordagem.

	Todas as Métricas	Sem a Potência
	(Média $\pm$ desvio padrão)	(Média $\pm$ desvio padrão)
<b>Accuracy</b>	0,88 $\pm$ 0,08	0,88 $\pm$ 0,08
<b>Sensibilidade</b>	0,92 $\pm$ 0,11	0,87 $\pm$ 0,13
<b>Precision</b>	0,84 $\pm$ 0,12	0,86 $\pm$ 0,14
<b>Especificidade</b>	0,87 $\pm$ 0,10	0,85 $\pm$ 0,15

Tabela 11-Resultados na utilização do modelo de random forest com o uso de todas as métricas e sem a utilização da potência para classificação

Através da análise da tabela 11 podemos considerar que, de um modo geral os nossos resultados são bastante satisfatórios com uma ligeira superioridade no caso em que utilizámos todas as métricas. Ainda assim obtivemos para os dois casos cerca de 88% de *accuracy*. Este conceito significa que os nossos modelos de classificação, tanto utilizando todas as métricas como retirando a potência, acertou corretamente aproximadamente 88% de todas as previsões possíveis. No entanto, como vimos anteriormente, um conceito bastante importante e que é particularmente relevante para o nosso objetivo neste projeto é a *sensibilidade*. Neste sentido podemos verificar que a utilização de todas métricas para o nosso modelo de classificação tem uma *sensibilidade* de 92%, ou seja, uma vantagem significativa de cerca de 5% comparado à performance do modelo que não utiliza a *potência*.

Concluimos assim, nesta abordagem, que, embora a *potência* não tenha uma influência significativa na performance do nosso modelo, ela ajuda o modelo a reconhecer melhor casos de fibrilação, pelo que não deve ser desprezada. Além disso podemos também averiguar desde já a diferença destes dois tipos de abordagens referentes ao *unsupervised* e *supervised learning* já que no primeiro caso a potência tem um papel irrelevante na correta classificação da doença.

## 4 Conclusão

Ao longo do presente estudo construiu-se um novo algoritmo para detecção automática de fibrilação ventricular (VF) através do ECG. Inicialmente todos os sinais escolhidos foram sujeitos a um pré-processamento de forma a melhorar a qualidade do sinal e serem corretamente analisados. Numa próxima fase extraiu-se 5 características do ECG tanto através da sua análise temporal como espectral e com base na literatura reportada. Numa fase intermédia, a construção de *boxplots* e elaboração de teste de hipóteses permitiu a avaliação das diferentes métricas do ECG e a avaliação da sua discriminação da condição patológica. Nesta primeira avaliação de resultados apenas a métrica relativa à frequência média não permitia distinguir a condição patológica pretendida, sendo assim descartada. Pelo lado contrário a métrica  $F1$  e  $N(\%)$  destacam-se como discriminatórias da condição. Finalmente procedeu-se à classificação onde se seguiu duas abordagens distintas: *Unsupervised* e *Supervised learning*. Assim, para o *unsupervised learning* utilizou-se o modelo *k-means* que se baseia numa técnica denominada “clustering”. O impacto de cada métrica é avaliado neste processo através da avaliação dos clusters gerados. Os resultados nesta primeira abordagem permitiram concluir que a métrica  $N(\%)$  é aquela que mais contribui e, mesmo usando apenas  $N(\%)$ , obtivemos uma *sensibilidade* de 100%, conseguindo agrupar os ECG's com a patologia sempre no mesmo grupo. Na aplicação do *Supervised learning* recorreu-se o uso do modelo de *random forests* que funciona através de sequências de regras de decisão. Os resultados obtidos para este último caso são de  $(0,92 \pm 0,11)$  % de *sensibilidade* aquando da utilização de todas as métricas. Ao contrário do *unsupervised learning*, a utilização do modelo de *random forest* revela uma melhor performance quando se utiliza todas as métricas em conjunto. Com isto, concluímos que obtivemos resultados bastante satisfatórios e que os mesmos foram congruentes com aqueles presentes na literatura. Além disso conseguimos mostrar as vantagens e desvantagens da utilização das métricas extraídas em conjunto ou em separado para os dois modelos. Assim, esperamos que este projeto permita a evolução de futuros trabalhos e estudos com o uso destas características do ECG.

## 5 Bibliografia

- [1] SNS, “Noticias-doenças cardiovasculares,” 2017. [Online]. Available: <https://www.sns.gov.pt/noticias/2017/10/04/doencas-cardiovasculares/>. [Accessed: 20-May-2021].
- [2] SNS, “Doenças cardiovasculares.” [Online]. Available: <https://www.sns.gov.pt/wp-content/uploads/2016/03/DoencasCardiovasculares.pdf>. [Accessed: 15-May-2021].
- [3] SNS24, “Arritmias cardíacas.” [Online]. Available: <https://www.sns24.gov.pt/tema/doencas-do-coracao/arritmias-cardiacas/>. [Accessed: 20-May-2021].
- [4] R. et al. Seeley, *Anatomia e Fisiologia, 6ª edição, Lusociência, Loures, 2003, Aparelho Circulatório, Circulação Pulmonar*, no. 680. .
- [5] U. Rajendra Acharya, J. S. Suri, J. A. E. Spaan, and S. M. Krishnan, *Advances in cardiac signal processing*. 2007.
- [6] S. Barro, R. Ruiz, D. Cabello, and J. Mira, “Algorithmic sequential decision-making in the frequency domain for life threatening ventricular arrhythmias and imitative artefacts: a diagnostic system,” *J. Biomed. Eng.*, vol. 11, no. 4, pp. 320–328, 1989.
- [7] A. Amann, R. Tratnig, and K. Unterkofler, “Reliability of old and new ventricular fibrillation detection algorithms for automated external defibrillators,” *Biomed. Eng. Online*, vol. 4, pp. 1–15, 2005.
- [8] M. A. Arafat, A. W. Chowdhury, and M. K. Hasan, “A simple time domain algorithm for the detection of ventricular fibrillation in electrocardiogram,” *Signal, Image Video Process.*, vol. 5, no. 1, pp. 1–10, 2011.
- [9] S. Hajeb-Mohammadipour, M. Ahmadi, R. Shahghadami, and K. H. Chon, “Automated method for discrimination of arrhythmias using time, frequency, and nonlinear features of electrocardiogram signals,” *Sensors (Switzerland)*, vol. 18, no. 7, 2018.
- [10] “Nolle FM, Badura FK, Catlett JM, Bowser RW, Sketch MH. CREI-GARD, a new concept in computerized arrhythmia monitoring systems. *Computers in Cardiology* 13:515-518 (1986).”
- [11] “Goldberger, A., et al. ‘PhysioBank, PhysioToolkit, and PhysioNet: Components of a new research resource for complex physiologic signals. *Circulation* [Online]. 101 (23), pp. e215–e220.’ (2000).”
- [12] A. M. Tomé, “Topics of the Lectures-Laboratórios de Engenharia Biomédica I,” p.28, 2019.
- [13] “Rangaraj M. Rangayyan. *Biomedical Signal Analysis: A Case Study Approach*. Wiley, 2012.”
- [14] A. Pinho, “Apontamentos de introdução ao processamento de sinal- Technical report.”
- [15] “Rangaraj M. Rangayyan. *Biomedical Signal Analysis*, chapter 6. Wiley and IEEE, 2015.”
- [16] D. F. Williamson, R. A. Parker, and J. S. Kendrick, “The box plot: A simple visual method to interpret data,” *Ann. Intern. Med.*, vol. 110, no. 11, pp. 916–921, 1989.
- [17] R. B. Davis and K. J. Mukamal, “Hypothesis testing: Means,” *Circulation*, vol. 114, no. 10, pp. 1078–1082, 2006.
- [18] MATHWORKS, [Online]. Available: <https://www.mathworks.com/help/stats/signrank.html>. [Accessed: 18-May-2021].
- [19] D. S. L. Julianna Delua, SME, IBM Analytics, “Supervised vs. Unsupervised Learning: What’s the Difference?,” 2021.
- [20] IBM Cloud Education, “Supervised Learning,” 2020.



## ANEXO A: Valores das métricas para cada paciente

Tabela 12-Valores de cada métrica para cada paciente na respetiva zona de fibrilação ventricular (c/VF) e na zona sem fibrilação ventricular(s/VF). Baseado nas medianas dos Boxplots.

Paciente	Freq.Média s/VF	Freq.Média c/VF	Freq.Fund. s/VF	Freq.Fund. c/VF	Potência s/VF	Potência c/VF	N(%) s/VF	N(%) c/VF	F1 s/VF	F1 c/VF
ecg01	6.9379	6.5309	2	7	63055	2.4877e+05	4.0667	67.733	0.011628	0.054864
ecg05	5.3626	5.0673	2.5	4.5	1.0895e+05	5.2145e+05	20.333	67.733	0.015961	0.049821
ecg6	2.9719	5.0577	1.5	4.5	3.7571e+05	1.6089e+05	54.2	58.733	0.025276	0.050043
ecg7	5.3728	6.5662	4	5.5	1.25e+05	42863	32.867	52.067	0.042253	0.050872
ecg10	6.9793	6.0361	6.5	4.5	1.101e+05	2.2386e+05	17.933	66.267	0.02622	0.046471
ecg11	3.1273	6.2906	2.5	5.5	3.7141e+05	1.3422e+05	43.067	57.867	0.024707	0.044732
ecg12	2.8047	4.0045	2.5	3.5	3.6963e+05	7.3329e+05	59.333	80.667	0.021454	0.047462
ecg15	3.8887	2.5718	1.5	2	1.3939e+05	6.3624e+05	33.733	80.733	0.0083376	0.02753
ecg16	6.6654	5.8452	6.5	4.5	2.1635e+05	5.8466e+05	38.133	74.4	0.02906	0.065353
ecg03	3.355	4.3832	2	4	1.0108e+05	96189	56.067	59.2	0.035319	0.035026
ecg04	5.518	2.7478	3	1	57026	1.3437e+05	19.867	61	0.01406	0.022062
ecg08	4.2907	4.0862	1	3.5	2.1961e+05	66859	30.667	50.067	0.022054	0.02554
ecg09	4.3656	4.3965	1.5	3.5	2.4544e+05	2.4696e+05	55.6	58	0.030948	0.02409
ecg13	5.2439	5.1772	3.5	3.5	1.4946e+05	6.1997e+05	29.067	76.067	0.030094	0.028869
ecg19	5.827	4.1329	4.5	3.5	1.5615e+05	7.2593e+05	40.467	74.267	0.033427	0.052232
ecg20	9.2221	3.8047	1.5	3	55886	2.0504e+05	7.2	66.133	0.015408	0.033512
ecg22	7.4639	4.5059	5.5	4	90961	2.0144e+05	7.6667	63.8	0.016977	0.031964
ecg23	7.4478	5.0737	6	4.5	89969	2.6558e+05	6.8667	65.2	0.02409	0.041114
ecg24	6.9008	5.4236	2.5	4.5	90931	2.2745e+05	6.1333	68.067	0.023121	0.049987
ecg26	5.5772	4.8724	2.5	4	1.6824e+05	2.0992e+05	33.067	73.8	0.044549	0.054953
ecg29	5.8247	3.1925	2	3	1.0555e+05	7.5427e+05	28	79.067	0.017419	0.048095
ecg30	2.187	6.6018	1	5.5	9.854e+05	70295	73.133	51.467	0.013261	0.041832
ecg32	3.9807	4.7412	1.5	3.5	1.8666e+05	55659	79.933	66	0.030102	0.034043
ecg33	8.0193	6.478	1.5	5.5	50682	90665	18.867	59.733	0.029974	0.042666
ecg34	4.4812	4.2149	1	4	58305	8.4893e+05	37.733	75.933	0.009477	0.049524